
Chapitre 3

Méthodes de classification

1 Introduction

La classification constitue une étape essentielle de l'analyse de données et de la Business Intelligence. Elle vise à organiser les données en groupes homogènes afin de faciliter leur interprétation et d'extraire des connaissances utiles à la prise de décision. Selon la disponibilité ou non des étiquettes de classes, on distingue la classification supervisée et la classification non supervisée, également appelée clustering.

Dans ce chapitre, nous présentons les principales méthodes de classification utilisées en Business Intelligence, à savoir le clustering *k-means*, l'algorithme *k-NN* (k-Nearest Neighbors) et le clustering par densité *DBSCAN*. Chaque méthode est expliquée de manière progressive, accompagnée d'exemples et d'applications concrètes.

2 Généralités sur la classification

2.1 Définition

Le clustering a pour objectif de créer des groupes d'observations homogènes, appelés *clusters*, tels que :

- les observations appartenant à un même groupe soient les plus semblables possible ;
- les groupes soient les plus différents possibles les uns des autres.

Le clustering est également connu sous les termes de classification automatique, segmentation ou classification non supervisée.

2.2 Notations

Soit un ensemble de n individus décrits par p variables explicatives :

$$X_i = (X_{i1}, X_{i2}, \dots, X_{ip}), \quad 1 \leq i \leq n$$

L'objectif est d'affecter chaque individu à un groupe :

$$Z_i \in \{1, \dots, K\}$$

L'ensemble des affectations $(Z_1, \dots, Z_n)$ forme une partition des données en K groupes.

2.3 Clustering vs classification supervisée

- **Clustering (non supervisé)** : les classes ne sont pas connues à l'avance. Elles sont construites à partir des données, puis interprétées.
- **Classification supervisée** : les classes sont connues a priori. L'objectif est de construire une règle de décision permettant de classer de nouveaux individus.

2.4 Applications en Business Intelligence

- Segmentation de clients (marketing, CRM)
- Analyse exploratoire des données
- Détection de fraudes
- Recommandation de produits
- Analyse prédictive

3 Notion de distance et interprétation des clusters

La plupart des méthodes de classification reposent sur une mesure de similarité ou de distance entre individus.

La notion de distance joue un rôle fondamental dans les méthodes de classification. Elle permet de mesurer la similarité entre deux individus décrits par plusieurs variables. Le choix de la distance influence directement la qualité des résultats.

Soient deux individus :

$$X = (x_1, x_2, \dots, x_p), \quad Y = (y_1, y_2, \dots, y_p)$$

Les principales distances utilisées sont :

- distance euclidienne ;
- distance de Manhattan ;
- distance cosinus.

3.1 Distance euclidienne

La distance euclidienne est la plus utilisée lorsque les variables sont numériques et normalisées. Elle est définie par :

$$d_E(X, Y) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$$

3.2 Distance de Manhattan

La distance de Manhattan, également appelée distance L_1 , est définie par :

$$d_M(X, Y) = \sum_{j=1}^p |x_j - y_j|$$

Elle est moins sensible aux valeurs aberrantes que la distance euclidienne.

3.3 Distance de Minkowski

La distance de Minkowski généralise les distances euclidienne et de Manhattan :

$$d_{Mk}(X, Y) = \left(\sum_{j=1}^p |x_j - y_j|^r \right)^{1/r}$$

Pour $r = 1$, on obtient la distance de Manhattan, et pour $r = 2$, la distance euclidienne.

3.4 Distance cosinus

La distance cosinus mesure l'angle entre deux vecteurs :

$$d_C(X, Y) = 1 - \frac{X \cdot Y}{\|X\| \|Y\|}$$

Elle est couramment utilisée pour des données textuelles ou de grande dimension.

*La distance euclidienne est la plus couramment utilisée, en particulier lorsque les données sont normalisées.

3.5 Interprétation d'une partition

Une partition obtenue peut être interprétée :

- en examinant des représentants de chaque cluster (centroïdes) ;
- en comparant les valeurs moyennes des variables dans chaque groupe.

3.6 Validation d'un clustering

La validation consiste à vérifier la pertinence des clusters obtenus, soit par comparaison avec une partition de référence, soit par l'analyse de la cohérence interne des groupes.

4 Clustering par la méthode K-means

4.1 Principe général

L'algorithme *k-means* est une méthode de clustering non supervisée visant à partitionner les données en K clusters. Chaque cluster est représenté par un centroïde correspondant à la moyenne des points qui lui sont affectés.

4.2 Fonctionnement de l'algorithme




FIGURE 1 – Algorithme K-means

L'algorithme K-means se déroule selon les étapes suivantes :

1. Initialisation aléatoire de K centroïdes ;
2. Affectation de chaque individu au centroïde le plus proche ;
3. Mise à jour des centroïdes par calcul de la moyenne ;
4. Répétition des étapes précédentes jusqu'à convergence.

4.3 Caractère non déterministe

K-means est un algorithme non déterministe : des initialisations différentes peuvent conduire à des partitions différentes pour un même jeu de données.

4.4 Exemple détaillé

Considérons un jeu de données composé de quatre individus décrits par deux variables numériques :

$$A(1, 1), \quad B(1, 3), \quad C(4, 3), \quad D(5, 4)$$

On souhaite appliquer l'algorithme K-means avec $K = 2$ clusters.

4.5 Étape 1 : initialisation des centroïdes

Choisissons arbitrairement deux centroïdes initiaux :

$$C_1^{(0)} = A(1, 1), \quad C_2^{(0)} = C(4, 3)$$

4.6 Étape 2 : calcul des distances

On calcule la distance euclidienne entre chaque point et les centroïdes.

$$d(A, C_1) = \sqrt{(1-1)^2 + (1-1)^2} = 0$$

$$d(A, C_2) = \sqrt{(1-4)^2 + (1-3)^2} = \sqrt{13}$$

De la même manière :

$$d(B, C_1) = 2, \quad d(B, C_2) = 3$$

$$d(C, C_1) = \sqrt{13}, \quad d(C, C_2) = 0$$

$$d(D, C_1) = 5, \quad d(D, C_2) = \sqrt{2}$$

4.7 Étape 3 : affectation des points

Chaque point est affecté au centroïde le plus proche :

— Cluster 1 : A, B

— Cluster 2 : C, D

4.8 Étape 4 : mise à jour des centroïdes

Les nouveaux centroïdes sont calculés comme la moyenne des points de chaque cluster.

$$C_1^{(1)} = \left(\frac{1+1}{2}, \frac{1+3}{2} \right) = (1, 2)$$

$$C_2^{(1)} = \left(\frac{4+5}{2}, \frac{3+4}{2} \right) = (4.5, 3.5)$$

Les étapes précédentes sont répétées jusqu'à convergence.

5 Classification supervisée par k-Nearest Neighbors (k-NN)

5.1 Principe de l'algorithme

L'algorithme k-NN est une méthode d'apprentissage supervisé utilisée pour la classification et la régression. Il consiste à classer un nouvel individu en fonction des k individus les plus proches dans l'espace des données.

5.2 Fonctionnement

Les étapes principales de k-NN sont :

- calcul des distances entre le nouvel individu et les données existantes ;
- sélection des k voisins les plus proches ;
- attribution de la classe majoritaire parmi ces voisins.

5.3 Exemple détaillé

Considérons un ensemble d'apprentissage composé de trois individus décrits par deux variables :

$$P_1(2, 2) \rightarrow \text{Classe } A$$

$$P_2(4, 4) \rightarrow \text{Classe } A$$

$$P_3(6, 6) \rightarrow \text{Classe } B$$

On souhaite classer un nouvel individu :

$$Q(5, 5)$$

avec $k = 3$.

5.4 Étape 1 : calcul des distances

$$d(Q, P_1) = \sqrt{(5-2)^2 + (5-2)^2} = \sqrt{18}$$

$$d(Q, P_2) = \sqrt{(5-4)^2 + (5-4)^2} = \sqrt{2}$$

$$d(Q, P_3) = \sqrt{(5-6)^2 + (5-6)^2} = \sqrt{2}$$

5.5 Étape 2 : sélection des voisins

Les trois plus proches voisins sont :

$$P_2, P_3, P_1$$

5.6 Étape 3 : vote majoritaire

Parmi les voisins :

— Classe A : 2 individus

— Classe B : 1 individu

Le point Q est donc classé dans la **classe A**.

Remarque :

Le choix du paramètre k influence fortement le résultat. Un k trop petit rend le modèle sensible au bruit, tandis qu'un k trop grand peut lisser excessivement les frontières de décision.

5.7 Exemple 2 KNN

Un exemple simple consiste à prédire la performance scolaire d'un élève à partir de ses heures d'étude et de sa note finale.

TABLE 1 – Jeu de données utilisé pour l'exemple de l'algorithme k-NN

Elève	Heures d'étude	Note finale	Catégorie
A	10	15	Bon
B	5	10	Moyen
C	2	5	Mauvais
D	8	13	Bon
E	3	7	Mauvais

5.8 Avantages et inconvénients

Avantages :

- simplicité de mise en œuvre ;
- applicable à la classification et à la régression ;
- absence de phase d'apprentissage complexe.

Inconvénients :

- coût de calcul élevé pour les grands jeux de données ;
- sensibilité au bruit ;
- choix délicat du paramètre k .

6 Clustering par densité : DBSCAN

6.1 Principe général

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) est un algorithme de clustering non supervisé basé sur la notion de densité. Contrairement à K-means, il ne nécessite pas de fixer le nombre de clusters à l'avance.

6.2 Paramètres de DBSCAN

DBSCAN repose sur deux paramètres principaux :

- **eps** : rayon définissant le voisinage d'un point ;
- **MinPts** : nombre minimum de points dans un voisinage pour former un cluster.

6.3 Types de points

DBSCAN distingue trois types de points :

- point central : possède au moins MinPts voisins ;
- point frontière : voisin d'un point central ;
- bruit : point isolé n'appartenant à aucun cluster.




FIGURE 2 – Clustering par densité DBSCAN

6.4 Étapes de l'algorithme

1. identification des points centraux ;
2. création des clusters ;
3. extension des clusters par connexité de densité ;
4. classification des points restants comme bruit.




FIGURE 3 – DBSCAN

7 Conclusion

Dans ce chapitre, nous avons étudié les principales méthodes de classification utilisées en Business Intelligence. Les algorithmes K-means, k-NN et DBSCAN présentent des approches complémentaires adaptées à différents types de données et d'objectifs. La maîtrise de ces techniques constitue un atout fondamental pour l'analyse, l'interprétation et la valorisation des données dans un contexte décisionnel.