
Chapitre 4

Les entrepôts de données et le processus ETL avec PygramETL

1 Introduction

Avec l'évolution rapide des systèmes d'information et l'explosion du volume des données, les organisations font face à un besoin croissant d'aide à la décision.

Les systèmes transactionnels classiques, bien qu'efficaces pour la gestion opérationnelle, ne permettent pas d'exploiter pleinement les données à des fins analytiques et stratégiques.

La **Business Intelligence (BI)** répond à ce besoin en fournissant des outils, des méthodes et des architectures permettant de transformer les données brutes en informations utiles pour la prise de décision. Au cœur de cette approche se trouvent les **systèmes décisionnels** et les **entrepôts de données (Data Warehouse)**.

Ce chapitre présente les concepts fondamentaux liés aux systèmes décisionnels, leurs composants, ainsi que les principes de conception et d'utilisation des entrepôts de données dans un contexte informatique moderne.

2 Systèmes décisionnels

Un **système décisionnel** est un système informatique destiné à soutenir les décideurs dans l'analyse des données historiques et actuelles afin de faciliter la prise de décisions stratégiques, tactiques ou opérationnelles. Contrairement aux systèmes transactionnels, il est orienté vers l'analyse, la synthèse et la visualisation de l'information.

2.1 Objectifs d'un système décisionnel

Les principaux objectifs d'un système décisionnel sont :

- Fournir une vision globale et cohérente des données de l'organisation.
- Faciliter l'analyse multidimensionnelle des données.

- Améliorer la qualité et la rapidité de la prise de décision.
- Réduire l'incertitude liée aux décisions stratégiques.

2.2 Composants d'un système décisionnel




FIGURE 1 – Ensemble des composants intervenant dans un système décisionnel (Source : 'Informatique Décisionnelle' NFE115)

Un système décisionnel repose sur plusieurs composants essentiels :

- **Sources de données** : bases de données opérationnelles, fichiers plats, données externes, API, capteurs.
- **Processus ETL (Extract, Transform, Load)** : extraction, nettoyage, transformation et chargement des données.
- **Entrepôt de données (Data Warehouse)**.
- **Data Marts** : sous-ensembles du Data Warehouse dédiés à un domaine spécifique.
- **Outils décisionnels** : reporting, tableaux de bord, OLAP, data mining.

Chaque composant joue un rôle précis dans la chaîne décisionnelle.

3 Sources de données

Les sources de données constituent la base de tout système décisionnel. Elles peuvent être très variées et hétérogènes.

3.1 Types de sources

On distingue principalement :

- **Sources internes** : ERP, CRM, systèmes comptables, bases de données métier.
- **Sources externes** : open data, partenaires, données web.
- **Données structurées** : bases relationnelles.
- **Données semi-structurées** : XML, JSON.
- **Données non structurées** : texte, images, logs.

La diversité des sources nécessite des mécanismes d'intégration performants.

—

4 Entrepôt de données (Data Warehouse)

L'entrepôt de données est un élément central du système décisionnel. Il permet de stocker des données intégrées, nettoyées et historisées afin de faciliter leur analyse. Il offre une vision centralisée de toutes les informations de l'entreprise. Contrairement aux bases de données opérationnelles, il est conçu pour structurer les données afin de simplifier leur analyse et soutenir les décisions des responsables.

4.1 Définition

Selon W. H. Inmon :

« Une collection de données orientée sujet, intégrée, non volatile et historisée, destinée à l'aide à la décision. »

Les données stockées dans un Data Warehouse proviennent de sources multiples et hétérogènes (bases transactionnelles, fichiers, applications métiers, etc.). Elles sont collectées, nettoyées, transformées et intégrées pour garantir cohérence, qualité et fiabilité.

4.2 Caractéristiques du Data Warehouse

- **Orientation sujet** : les données sont organisées autour de thèmes majeurs (ventes, clients, produits, etc.).

- **Intégration** : les données provenant de sources hétérogènes sont unifiées selon des conventions communes.

- **Historisation** : conservation sur une longue période, permettant l'analyse temporelle.




FIGURE 2 – Données Orientées Sujets




FIGURE 3 – Données Intégrées

- **Non-volatilité** : les données ne sont pas modifiées ou supprimées après chargement.




FIGURE 4 – Données Historisées et Non Volatiles du DW

5 Processus ETL

Le processus ETL (Extract, Transform, Load) est utilisé pour collecter, transformer et charger les données dans le Data Warehouse.

- **Extraction (Extract)** : récupération des données brutes depuis les différentes sources, sans perturber les systèmes opérationnels.
- **Transformation (Transform)** : nettoyage, normalisation, enrichissement et restructuration des données pour l'analyse.
- **Chargement (Load)** : insertion des données transformées dans l'entrepôt de données (périodique, incrémental ou quasi temps réel).

Les données sont ensuite organisées selon des modèles adaptés (schéma en étoile ou en flocon) pour faciliter l'exploration et l'analyse.

6 Architecture d'un système décisionnel

Une architecture décisionnelle classique comprend plusieurs couches, de la source de données à l'analyse décisionnelle.




FIGURE 5 – Architecture d'un système décisionnel

Concept	Définition / rôle	Exemple / usage
Système décisionnel (DSS)	Ensemble de méthodes et outils pour la prise de décision	Tableau de bord stratégique
Source de données	Origine des informations	ERP, CRM, fichiers, capteurs
Entrepôt de données (DW)	Base centralisée, intégrée et historisée	Stockage de ventes sur 5 ans
Architecture décisionnelle	Organisation des données et couches pour l'analyse	OLTP → ODS → DW → Datamart → OLAP
OLTP	Bases transactionnelles	Saisie des commandes en temps réel
OLAP	Outils pour analyser les données	Cube pour ventes par région et période
LTC (Long Term Storage)	Stockage longue durée des données pour analyses	Historique complet des ventes depuis 10 ans

TABLE 1 – Comparaison des concepts du décisionnel

7 Systèmes OLTP et OLAP

7.1 OLTP (Online Transaction Processing)

Ces systèmes sont destinés au traitement des transactions quotidiennes :

- Grand nombre de requêtes simples.
- Opérations d'insertion, modification et suppression.
- Structure normalisée pour éviter les redondances.

7.2 OLAP (Online Analytical Processing)

Ces systèmes sont destinés à l'analyse décisionnelle :

- Analyse multidimensionnelle.
- Agrégation des données.
- Exploration interactive.

7.3 Comparaison OLTP / OLAP

Critère	OLTP	OLAP
Objectif	Gestion opérationnelle	Analyse décisionnelle
Type de données	Actuelles	Historiques
Requêtes	Simple	Complexes
Temps de réponse	Très court	Variable

—

8 Rôle du Data Warehouse en BI

Le Data Warehouse constitue la pierre angulaire de la BI :

- Alimentation des tableaux de bord.
- Analyse des performances.
- Détection de tendances.
- Support à la planification stratégique.

—

9 Exemple illustratif

Dans une entreprise commerciale, le Data Warehouse peut regrouper les données de ventes, clients et produits. Les décideurs peuvent ainsi analyser :

- L'évolution des ventes par période.
- La performance des produits.
- Le comportement des clients.



FIGURE 6 – Dashboard

10 Conclusion

Les systèmes décisionnels et les entrepôts de données jouent un rôle fondamental dans la Business Intelligence. Ils permettent de transformer des volumes importants de données en informations stratégiques exploitables.



FIGURE 7 – Management Overview



FIGURE 8 – Management Dashboard