
Chapitre 5

Modélisation multidimensionnelle dans les entrepôts de données

1 Introduction

La modélisation multidimensionnelle constitue un élément fondamental des systèmes décisionnels et de la Business Intelligence (BI). Elle vise à organiser les données issues des entrepôts de données de manière à faciliter l'analyse, l'exploration et l'aide à la prise de décision. Contrairement aux bases de données transactionnelles classiques, qui sont conçues pour gérer des opérations courantes, la modélisation multidimensionnelle est spécifiquement orientée vers l'analyse analytique et historique des données.

Ce type de modélisation permet aux décideurs d'analyser les données selon plusieurs axes d'observation, appelés dimensions, et d'examiner des indicateurs chiffrés, appelés faits ou mesures. Elle constitue ainsi la base conceptuelle des systèmes OLAP (Online Analytical Processing).

2 Principes de la modélisation multidimensionnelle

La modélisation multidimensionnelle repose sur une représentation des données sous forme de structures simples et intuitives. Elle vise à répondre efficacement à des questions analytiques complexes telles que :

- Quelle est l'évolution des ventes dans le temps ?
- Quels produits sont les plus performants par région ?
- Comment se comportent les indicateurs selon différents segments de clients ?

Cette modélisation s'appuie principalement sur deux types de tables :

- les tables de faits ;
- les tables de dimensions.

3 Vue multidimensionnelle des données

Dans un système décisionnel, les données sont souvent représentées sous forme de cube multidimensionnel. Chaque axe du cube correspond à une dimension d'analyse (temps, produit, localisation, client, etc.), tandis que les cellules du cube contiennent des mesures numériques.

Cette représentation permet une exploration flexible des données selon différentes perspectives, favorisant ainsi l'analyse comparative et l'identification de tendances.

4 Les tables de faits

Une table de faits est la table centrale de la modélisation multidimensionnelle. Elle contient les mesures quantitatives associées à un processus métier donné.




FIGURE 1 – Tables de Faits

4.1 Caractéristiques des tables de faits

Les tables de faits se caractérisent par :

- la présence de mesures numériques (montant, quantité, durée, etc.) ;
- la présence de clés étrangères référant aux tables de dimensions ;
- un niveau de granularité bien défini.

4.2 Granularité

La granularité correspond au niveau de détail des données stockées dans la table de faits. Un choix approprié de la granularité est essentiel afin d'assurer un bon compromis entre précision analytique et volume de données.

5 Les tables de dimensions

Les tables de dimensions fournissent le contexte nécessaire à l'interprétation des mesures contenues dans les tables de faits. Elles décrivent les entités selon lesquelles l'analyse est réalisée.

5.1 Rôle des tables de dimensions

Les dimensions répondent généralement aux questions suivantes :

- Qui ?
- Quoi ?
- Où ?
- Quand ?

Chaque table de dimension contient des attributs descriptifs et peut inclure des hiérarchies permettant une analyse à différents niveaux.

—

6 La dimension temps

La dimension temps est une composante essentielle de presque tous les entrepôts de données. Elle permet d'analyser l'évolution des indicateurs dans le temps.

6.1 Attributs de la dimension temps

Une dimension temps contient généralement :

- jour ;
- mois ;
- trimestre ;
- année ;
- indicateurs calendaires.

Cette dimension facilite les analyses temporelles telles que les comparaisons annuelles et les études de tendance.

—

7 Autres dimensions courantes

Outre la dimension temps, plusieurs dimensions sont fréquemment utilisées dans les systèmes décisionnels :

- dimension produit ;
- dimension client ;

- dimension localisation ;
- dimension organisationnelle.

Ces dimensions enrichissent l'analyse en apportant une vision détaillée et contextuelle des données.

8 Les modèles de données dans les entrepôts de données

Dans le contexte des entrepôts de données, la modélisation des informations ne repose pas sur les modèles relationnels classiques utilisés dans les systèmes transactionnels. Elle adopte des modèles spécifiquement conçus pour l'analyse décisionnelle.

Ces modèles visent à organiser les données de manière à :

- faciliter les analyses multidimensionnelles ;
- optimiser les performances des requêtes analytiques ;
- simplifier la compréhension des données par les décideurs.

Les modèles de données en Data Warehouse sont généralement matérialisés par des **schémas multidimensionnels**. Les plus couramment utilisés sont :

- le schéma en étoile ;
- le schéma en flocon ;
- le modèle en constellation.

Ces schémas représentent différentes manières d'organiser les tables de faits et de dimensions selon le niveau de complexité du système décisionnel et les besoins analytiques.

9 Schéma en étoile (Star Schema)

Le schéma en étoile est la structure la plus utilisée en modélisation multidimensionnelle.




FIGURE 2 – Modèle en étoile

9.1 Structure

Il se compose :

- d'une table de faits centrale ;
- de plusieurs tables de dimensions directement reliées à la table de faits.

9.2 Avantages

Le schéma en étoile offre :

- une simplicité de conception ;
- de bonnes performances de requêtage ;
- une compréhension intuitive pour les utilisateurs.

9.3 Requêtes analytiques dans un schéma en étoile

La simplicité structurelle du schéma en étoile facilite l'écriture de requêtes analytiques basées sur des opérations d'agrégation et de regroupement. Ces requêtes permettent de produire des indicateurs synthétiques à partir des données historiques.

La structure générale d'une requête analytique dans un entrepôt de données peut être exprimée comme suit :

```
SELECT liste_de_projection,  
       fonctions_d_aggregation  
FROM table_de_faits  
JOIN tables_de_dimensions  
WHERE conditions_de_filtrage  
GROUP BY attributs_d_analyse  
HAVING conditions_sur_aggregats
```

9.4 Exemple de requête analytique

Une requête permettant de calculer le chiffre d'affaires par produit et par année peut s'écrire conceptuellement comme :

- projection : produit, année ;
- agrégation : somme des montants ;
- regroupement : par produit et par année.

Ce type de requête est typique des analyses OLAP et illustre l'efficacité du schéma en étoile pour les systèmes décisionnels.

10 Schéma en flocon (Snowflake Schema)

Le schéma en flocon est une variante du schéma en étoile dans laquelle les tables de dimensions sont normalisées.




FIGURE 3 – Modèle en Flocon

10.1 Caractéristiques

Dans ce schéma, certaines dimensions sont décomposées en plusieurs tables liées, ce qui permet une meilleure organisation des données descriptives.

10.2 Avantages et limites

Le schéma en flocon permet :

- une réduction de la redondance des données ;
- une optimisation de l'espace de stockage.

Cependant, il peut entraîner une complexité accrue des requêtes.

11 Modèle en constellation

Le modèle en constellation, également appelé *galaxy schema*, est une extension du schéma en étoile. Il est utilisé lorsque le système décisionnel doit analyser plusieurs processus métiers simultanément.

Contrairement au schéma en étoile, qui comporte une seule table de faits, le modèle en constellation repose sur plusieurs tables de faits partageant des dimensions communes.



FIGURE 4 – Modèle en Constellation

11.1 Structure du modèle en constellation

Un modèle en constellation se compose de :

- plusieurs tables de faits représentant différents processus métiers ;
- des tables de dimensions communes (temps, produit, localisation, etc.) ;
- des relations multiples entre faits et dimensions.

Ce type de modélisation permet une analyse transversale et cohérente des données à travers différents domaines d'activité.

11.2 Exemple de modèle en constellation

Dans un système décisionnel commercial, on peut retrouver :

- une table de faits **Ventes** ;
- une table de faits **Achats** ;
- une table de faits **Stocks** ;

Ces tables peuvent partager des dimensions communes telles que la dimension **Temps**, la dimension **Produit** et la dimension **Localisation**.

11.3 Avantages du modèle en constellation

Le modèle en constellation présente plusieurs avantages :

- représentation fidèle des systèmes réels ;
- partage des dimensions entre plusieurs processus métiers ;
- réduction de la redondance des données ;
- amélioration de la cohérence analytique.

11.4 Limites du modèle en constellation

Malgré ses avantages, ce modèle présente certaines limites :

- complexité de conception ;
- complexité accrue des requêtes SQL ;
- besoin d’une gouvernance rigoureuse des dimensions.

12 Comparaison des modèles

Critère	Étoile	Flocon	Constellation
Nombre de faits	1	1	Plusieurs
Complexité	Faible	Moyenne	Élevée
Performance	Élevée	Moyenne	Variable
Cas d’usage	Simple	Intermédiaire	Avancé

13 Lien entre modélisation multidimensionnelle et OLAP

La modélisation multidimensionnelle constitue le fondement des systèmes OLAP. Elle permet l’exécution d’opérations analytiques telles que :

- roll-up ;
- drill-down ;
- slice ;
- dice.

Ces opérations facilitent l’exploration interactive des données selon différents niveaux de détail.

—

14 Avantages de la modélisation multidimensionnelle

La modélisation multidimensionnelle présente plusieurs avantages :

- amélioration des performances analytiques ;
- simplicité de compréhension ;
- orientation décisionnelle ;
- flexibilité d’analyse.

15 Outils de Business Intelligence et Data Warehouse

Les systèmes décisionnels reposent sur un ensemble d’outils permettant la collecte, le stockage, l’analyse et la visualisation des données. Ces outils peuvent être classés en deux grandes catégories : les solutions open source et les solutions propriétaires.

15.1 Outils open source

Les outils open source sont largement utilisés dans les environnements académiques et professionnels en raison de leur flexibilité et de leur coût réduit. Parmi les solutions les plus connues, on peut citer :

- Pentaho pour l'analyse et la visualisation ;
- Talend pour les processus ETL ;
- PostgreSQL comme entrepôt de données relationnel ;
- Apache Hive pour l'analyse de données massives.

15.2 Outils propriétaires

Les solutions propriétaires offrent des plateformes intégrées, robustes et orientées entreprise. Elles sont souvent utilisées dans les grandes organisations :

- Microsoft SQL Server et Analysis Services ;
- Oracle Data Warehouse ;
- SAP Business Warehouse ;
- IBM Cognos Analytics.

16 Implémentation logique d'un entrepôt de données

La mise en œuvre d'un entrepôt de données repose sur une implémentation logique basée sur des tables de faits et des tables de dimensions. Cette implémentation diffère fondamentalement des bases de données transactionnelles.

16.1 Création des tables de dimensions

Les tables de dimensions sont créées avec une clé primaire unique et des attributs descriptifs permettant l'analyse :

```
CREATE TABLE Dim_Temps (  
    id_temps INT PRIMARY KEY,  
    jour INT,  
    mois INT,  
    annee INT  
);
```

16.2 Création de la table de faits

La table de faits contient les mesures et les clés étrangères vers les dimensions :

```
CREATE TABLE Fait_Ventes (  
    id_temps INT,  
    id_produit INT,  
    montant DECIMAL,  
    quantite INT,  
    FOREIGN KEY (id_temps) REFERENCES Dim_Temps(id_temps)  
);
```

Cette structure permet d'assurer l'intégrité des données tout en facilitant les analyses multidimensionnelles.

17 Conclusion

La modélisation multidimensionnelle joue un rôle central dans la conception des entrepôts de données et des systèmes décisionnels. En structurant les données autour de tables de faits et de dimensions, elle permet une analyse efficace, intuitive et orientée vers l'aide à la décision. Ce modèle constitue ainsi un pilier fondamental de la Business Intelligence moderne.