
Chapitre 6

Exploration et Visualisation des Données en Business Intelligence

1 Introduction

Dans un contexte de Business Intelligence (BI), les données stockées dans les entrepôts de données n'ont de valeur que si elles peuvent être comprises, analysées et interprétées correctement. L'exploration et la visualisation des données constituent une étape essentielle du processus décisionnel, car elles permettent de transformer des données brutes en informations exploitables.

Ce chapitre a pour objectif de présenter les concepts fondamentaux de l'exploration des données ainsi que les principales techniques de visualisation utilisées en BI, en s'appuyant sur des exemples pratiques réalisés avec Python.

2 Rôle de l'exploration et de la visualisation en BI

L'exploration et la visualisation des données interviennent après la phase de stockage et de modélisation des données dans un entrepôt de données. Elles permettent notamment :

- de comprendre la structure et la qualité des données,
- d'identifier les valeurs manquantes ou aberrantes,
- de détecter des tendances et des corrélations,
- de faciliter la prise de décision stratégique.

Dans un système de BI, ces étapes constituent un lien direct entre les données et les décideurs.

3 Exploration des données

3.1 Définition

L'exploration des données (Data Exploration) consiste à analyser un ensemble de données afin d'en comprendre les caractéristiques principales avant toute analyse approfondie ou modélisation.

3.2 Types de variables

Les données manipulées en BI peuvent être classées en :

- **Variables numériques** : quantitatives discrètes ou continues (ex. : chiffre d'affaires, quantité).
- **Variables catégorielles** : qualitatives nominales ou ordinales (ex. : région, catégorie de produit).
- **Variables temporelles** : dates, périodes, années.

3.3 Analyse de la structure des données

L'analyse de la structure permet d'identifier :

- le nombre d'observations,
- le nombre de variables,
- le type de chaque variable.

3.4 Statistiques descriptives

Les statistiques descriptives résument les données à l'aide de mesures simples telles que :

- la moyenne,
- la médiane,
- le minimum et le maximum,
- l'écart-type.

4 Valeurs manquantes et valeurs aberrantes

4.1 Valeurs manquantes

Les valeurs manquantes peuvent être dues à des erreurs de saisie, des problèmes de collecte ou des données incomplètes. Elles doivent être identifiées et traitées avant toute analyse.

4.2 Valeurs aberrantes

Les valeurs aberrantes (outliers) sont des valeurs très éloignées de la majorité des observations. Elles peuvent fausser les analyses statistiques et doivent être détectées à l'aide de méthodes graphiques ou statistiques.

5 Exploration des données avec Python

5.1 Présentation de pandas

La bibliothèque `pandas` est largement utilisée en BI pour la manipulation et l'exploration des données.

5.2 Chargement des données

```
import pandas as pd
```

```
data = pd.read_csv("ventes.csv")
```

5.3 Aperçu des données

```
data.head()
```

```
data.info()
```

5.4 Statistiques descriptives

```
data.describe()
```

5.5 Analyse des valeurs manquantes

```
data.isnull().sum()
```

```
data.isnull().mean() * 100
```

6 Visualisation des données

6.1 Définition

La visualisation des données consiste à représenter graphiquement les données afin de faciliter leur compréhension et leur interprétation.

6.2 Importance de la visualisation en BI

La visualisation permet :

- une interprétation rapide des résultats,
- une communication efficace avec les décideurs,
- une meilleure détection des tendances.

7 Types de graphiques utilisés en BI

Type de graphique	Utilisation en Business Intelligence
Histogramme	Analyse de la distribution d'une variable numérique (ventes, montants, quantités).
Diagramme en barres	Comparaison entre différentes catégories (produits, régions, années).
Diagramme circulaire	Représentation des proportions ou parts relatives.
Boîte à moustaches	Détection des valeurs aberrantes (outliers) et dispersion des données.
Nuage de points	Analyse de la relation entre deux variables numériques.
Carte de chaleur	Visualisation des corrélations entre plusieurs variables.

TABLE 1 – Principaux types de graphiques utilisés en Business Intelligence

8 Visualisation avec Matplotlib

8.1 Histogramme




FIGURE 1 – Histogramme

```
import matplotlib.pyplot as plt
```

```
plt.hist(data['MontantVente'], bins=10)

plt.title("Distribution des ventes")

plt.xlabel("Montant")

plt.ylabel("Fréquence")

plt.show()
```

8.2 Diagramme en barres




FIGURE 2 – Diagramme en barres

```
data['Region'].value_counts().plot(kind='bar')

plt.title("Ventes par région")

plt.show()
```

8.3 Boîte à moustaches

```
plt.boxplot(data['MontantVente'])

plt.title("Analyse des valeurs aberrantes")

plt.show()
```




FIGURE 3 – Boxplot (Boîte à moustaches)

9 Visualisation avancée avec Seaborn

9.1 Nuage de points




FIGURE 4 – Nuage de points

```
import seaborn as sns
```

```
sns.scatterplot(x='MontantVente', y='Quantite', data=data)
```

```
plt.show()
```

9.2 Carte de chaleur (Heatmap)

```
corr = data.corr()
```

```
sns.heatmap(corr, annot=True)
```

```
plt.show()
```




FIGURE 5 – Heatmap

10 Techniques d'analyse visuelle

10.1 Analyse univariée

Elle consiste à étudier une seule variable à la fois à l'aide d'histogrammes ou de diagrammes en barres.

10.2 Analyse bivariée

Elle permet d'analyser la relation entre deux variables, par exemple à l'aide d'un nuage de points.

10.3 Analyse multivariée

Elle permet d'étudier simultanément plusieurs variables pour détecter des relations complexes.

11 Bonnes pratiques de visualisation

- Choisir le graphique adapté au type de données.
- Ajouter titres, légendes et labels.
- Éviter la surcharge visuelle.
- Mettre en évidence les informations importantes.

12 Exemple complet d'exploration et visualisation

```
print(data.info()) print(data.describe())
sns.boxplot(x='MontantVente', data=data) plt.show()
```

```
sns.scatterplot(x='MontantVente', y='Quantite', data=data) plt.show()
```

13 Exercices

1. Charger un fichier CSV et afficher ses premières lignes.
2. Identifier les valeurs manquantes.
3. Tracer un histogramme pour une variable numérique.
4. Créer un diagramme en barres pour une variable catégorielle.
5. Détecter les valeurs aberrantes à l'aide d'un boxplot.

14 Conclusion

L'exploration et la visualisation des données constituent une étape fondamentale en Business Intelligence. Elles permettent de comprendre les données, de détecter les anomalies et d'extraire des informations utiles à la prise de décision.