
Série 2

Exercice QCM :

1. Quel composant ne fait pas partie d'un processus ETL ?
 - a) Extraction
 - b) Transformation
 - c) Virtualisation
 - d) Chargement

2. Un Data Mart est :
 - a) Une base OLTP
 - b) Une partie spécifique d'un entrepôt de données
 - c) Un logiciel d'extraction
 - d) Un outil de datamining

3. L'analyse OLAP est caractérisée par :
 - a) Une analyse multidimensionnelle des données
 - b) Une forte fréquence d'écriture
 - c) Une logique transactionnelle
 - d) Une analyse linéaire des flux

4. Dans un cube OLAP, une "mesure" correspond :
 - a) À une valeur numérique agrégée (ex. : total des ventes)
 - b) À une règle métier
 - c) À un filtre de sécurité
 - d) À une valeur numérique agrégée (ex. : total des ventes)

5. Quel outil est typiquement utilisé pour la visualisation dans la BI ?
 - a) MySQL
 - b) Power BI
 - c) Hadoop
 - d) Git

6. L'approche OLTP est conçue pour :
 - a) La prévision

- 7) Un histogramme est utile pour :
- a) Voir les relations entre deux variables
 - b) Observer la distribution d'une variable
 - c) Comparer des catégories
 - d) Trier les colonnes

- 8) Le nettoyage des données ne comprend PAS :
- a) L'analyse des sentiments
 - b) Le traitement des valeurs manquantes
 - c) La suppression des doublons
 - d) Le traitement des outliers

- 9) Dans un processus ETL, quelle est une action typique de la phase "Transform" ?
- a) Lire un fichier CSV
 - b) Enrichir, nettoyer ou convertir les données
 - c) Nettoyer et Sauvegarder les données dans Excel
 - d) Exporter un graphique

- 10) Pourquoi nettoie-t-on les données avant l'analyse ?
- a) Pour décorer le fichier
 - b) Pour éviter les erreurs et améliorer la fiabilité des résultats
 - c) Pour rendre le code plus rapide
 - d) Pour remplir les cellules vides au hasard

- 11) Quelle est la principale différence entre OLTP et OLAP ?
- a) OLTP sert à l'analyse stratégique, OLAP à la gestion courante
 - b) OLTP stocke des données historiques, OLAP des données en temps réel
 - c) OLTP gère les transactions opérationnelles, OLAP réalise des analyses décisionnelles
 - d) OLAP est plus rapide que OLTP pour l'écriture de données

- 12) Le fait qu'un entrepôt de données soit historisé signifie que :
- a) Les données sont supprimées régulièrement
 - b) Les anciennes versions des données sont conservées
 - c) Les données sont stockées uniquement pour l'année en cours
 - d) L'horodatage est effacé

- 13) Le nettoyage des données ne comprend généralement pas :
- a) La gestion des valeurs manquantes
 - b) La suppression des doublons
 - c) L'analyse des sentiments
 - d) Le traitement des outliers

- 14) Un outlier (valeur aberrante) peut :
- a) Être utile pour le clustering
 - b) Être toujours automatiquement supprimé
 - c) Réduire la précision des dimensions
 - d) Fausser fortement les résultats analytiques

- 15) Dans K-NN, que représente le paramètre k ?
- a) Le nombre de classes cibles

- b) L'analyse historique
- c) Les opérations courantes et en temps réel
- d) La création de cubes

7. Quel algorithme est le plus adapté pour un problème de segmentation client ?

- a) KNN
- b) K-means
- c) Naïve Bayes
- d) SVM

8. Dans le contexte BI, que signifie "nettoyage des données" ?

- a) Les supprimer
- b) Corriger les erreurs et gérer les valeurs manquantes
- c) Les anonymiser
- d) Les convertir en texte

Exercice 1 : Complète le tableau suivant en comparant OLTP et OLAP :

Critère	OLTP	OLAP
Type d'opérations	En temps réel / Transactionnelle	Analyse historique (Analytique)
Fréquence des accès	transaction courte	Faible (longues requêtes)
Nature des données	actuelle / dynamique	historique / statique
Exemple d'usage	Gestion de vente	Rapport annuelle
Optimisé pour	Rapidité d'intégrité + écriture	analyse multidimensionnelle

Exercice 2 :

- a. C'est quoi BI ?
- b. Quelle est l'importance de BI ? analyse historique
- c. Quel est l'objectif de BI ? analyse stratégique
- d. Qu'est-ce qu'un Data Warehouse et pourquoi est-il utilisé en BI ?
- e. Décrire le processus ETL et son importance en BI.

Exercice 3 : Une entreprise de livraison souhaite construire un Data Warehouse pour analyser ses livraisons.

Question :

Décris au moins 3 dimensions et 2 mesures que tu inclurais dans un schéma en étoile pour cette entreprise.

Exercice 4 :

ID_Facture	ID_Temps	ID_Produit	ID_Client	Montant
1	202301	A12	C05	250

Question :

À quoi servent les ID_Temps, ID_Produit et ID_Client ? Explique pourquoi on utilise des dimensions séparées.

Exercice 2 :

- c'est l'ensemble de technologies et stratégies utilisées par les entreprises pour l'analyse de données afin de fournir des informations exploitables.
 - Elle permet de transformer des données brutes en connaissances pour réduire l'incertitude.
 - L'objectif principal du BI est de soutenir la prise de décision stratégique basée sur des faits plutôt que sur l'intuition.
 - Qu'est ce qu'un Data Warehouse ?
C'est une base de données centrale qui stocke des données provenant de diverses sources. On l'utilise du BI pour séparer les données d'analyse des données de production.
 - Extrait : Récupération des données sources
 - Transform : Nettoyage et mise au format (conversion, filtrage)
 - Load : Chargement dans le Data Warehouse.
- => garantir la qualité et l'homogénéité des données pour l'analyse.

Exercice 3 :

Pour l'analyse des livraisons, voici une proposition de schéma en étoile :

Table de fait : Fait - livraisons

Mesures : Délai - livraison, Frais - transport.

Dimensions:

- 1 - Dim - temps (Date, mois, année, jour)
- 2 - Dim - Véhicule (Type, matricule, capacité)
- 3 - Dim - Destination (Ville, code postale, région)

Exercice 4 :

- ID_Temps, ID-produit et ID-client : des étrangères (3 dimensions de la table de fait)
servent à lier la table de fait
- On utilise des dimension séparées pour : réduire la redondance
garantir la performance (rapidité (filtrage + regroupement)
garantir la flexibilité (permet une analyse multiple)