



TP3

Dataset utilisé : Supermarket Sales Dataset (Supermarket_Sales.csv)

Objectif : Passer d'une analyse descriptive à une analyse comportementale et stratégique.

1. Analyse initiale du Dataset

1. Vérifier la taille du dataset : `df.shape`
2. Vérifier les types des variables : `df.info()`
3. Vérifier les statistiques descriptives : `df.describe()`
4. Vérifier les valeurs manquantes :

`df.isnull().sum()`

`df.isnull().values.any()`

2. Calcul des KPI

Calculer les indicateurs suivants :

1. Chiffre d'affaires total : `df['Total'].sum()`
2. Profit total : `df['gross income'].sum()`
3. Nombre total de ventes : `df.shape[0]`
4. Panier moyen : `df['Total'].mean()`

Interpréter les résultats obtenus.

3. Segmentation Clients avec K-Means

3.1 Sélection des variables

Variables utilisées : Total, Quantity, Rating

`X = df[['Total', 'Quantity', 'Rating']]`

3.2 Standardisation

```
from sklearn.preprocessing import StandardScaler
```

```
scaler = StandardScaler()
```

```
X_scaled = scaler.fit_transform(X)
```

Expliquer pourquoi la standardisation est nécessaire avant K-Means.

3.3 Application de K-Means

Nous fixons le nombre de clusters à $K = 3$.

Vous devez tester $K = 2$ ou $K = 4$ pour comparer.

```
from sklearn.cluster import KMeans
```

```
k = 3
```

```
kmeans = KMeans(n_clusters=k, random_state=42)
```

```
df['Cluster'] = kmeans.fit_predict(X_scaled)
```

3.4 Visualisation des clusters

```
import matplotlib.pyplot as plt
```

```
plt.figure()
```

```
plt.scatter(df['Total'], df['Quantity'], c=df['Cluster'])
```

```
plt.xlabel('Total')
```

```
plt.ylabel('Quantity')
```

```
plt.title('Segmentation Clients')
```

```
plt.show()
```

3.5 Analyse Business des Clusters

```
df.groupby('Cluster')[['Total', 'Quantity', 'Rating']].mean()
```

Pour chaque cluster :

- Décrire le profil des clients.
- Identifier le cluster le plus rentable.
- Identifier le cluster le plus fidèle (rating).

-