

TP4 : Exploration des données et création d'un Dashboard

Objectif

- Explorer un nouveau dataset
- Créer des indicateurs clés de performance (KPI)
- Visualiser les données
- Construire un dashboard simple

Dataset : Titanic

Le dataset Titanic contient des informations sur les passagers du Titanic. Les principales colonnes utilisées dans ce TP sont :

- **Survived** : 0 = non survivant, 1 = survivant
- **Pclass** : classe du billet (1, 2, 3)
- **Sex** : sexe du passager
- **Age** : âge du passager
- **Fare** : prix du billet

Partie 1 : Exploration des données

```
import pandas as pd

df = pd.read_csv("titanic.csv")
```

Questions :

- afficher les 5 premières et dernières lignes (code python)
- Combien de lignes et de colonnes contient le dataset ?
- Y a-t-il des valeurs manquantes ?

Partie 2 : Création des KPI

Calculer les indicateurs suivants :

- Nombre total de passagers
- Nombre de survivants
- Prix moyen du billet (Fare)
- (Bonus) Taux de survie

Partie 3 : Analyse

Questions :

- Qui survit le plus : les hommes ou les femmes ?
- Quelle classe paie le plus cher ?

Partie 4 : Visualisation

```
import matplotlib.pyplot as plt

# Survie par sexe
df.groupby('Sex')['Survived'].sum().plot(kind='bar')
plt.show()

# Prix moyen par classe
df.groupby('Pclass')['Fare'].mean().plot(kind='bar')
plt.show()
```

Partie 5 : Dashboard

Définition :

Un **dashboard** (tableau de bord) est un ensemble de visualisations (graphiques, indicateurs) regroupées dans une seule vue afin de faciliter la prise de décision.

Création d'un dashboard simple :

```
fig, axs = plt.subplots(1, 2, figsize=(10,4))

# Survie par sexe
df.groupby('Sex')['Survived'].sum().plot(kind='bar', ax=axs[0])
axs[0].set_title("Survie par sexe")

# Prix moyen par classe
df.groupby('Pclass')['Fare'].mean().plot(kind='bar', ax=axs[1])
axs[1].set_title("Prix moyen par classe")

plt.tight_layout()
plt.show()
```

Partie 6 : Interprétation

- Qui a le plus de chances de survivre ?
- Quelle classe est la plus chère ?
- Donner une conclusion générale