

TP 5: Data Preparation & Data Visualization

Objectifs

- Explorer un dataset, Préparer et nettoyer les données, Visualiser les données, Interpréter les résultats

Dataset : Titanic

Colonnes utilisées :

- Survived : 0 = non survivant, 1 = survivant
- Pclass : classe du billet (1,2,3)
- Sex : sexe
- Age : âge
- Fare : prix du billet

Partie 1 : Préparation des données

Étape	Code	Objectif
Exploration	<code>df.head()</code> <code>df.shape</code> <code>df.isnull().sum()</code>	Comprendre les données
Nettoyage	<code>df['Age'].fillna(df['Age'].mean(), inplace=True)</code>	Traiter valeurs manquantes
Encodage	<code>df['Sex']=df['Sex'].map({'male':0,'female':1})</code>	Transformer variable catégorielle

Partie 2 : Visualisation des données

Graphique	Code	Objectif
Histogramme	<code>df['Age'].plot(kind='hist')</code>	Distribution des âges
Barplot	<code>df['Sex'].value_counts().plot(kind='bar')</code>	Comparaison hommes/femmes
Boxplot	<code>df.boxplot(column='Fare')</code>	Détection valeurs extrêmes
Barplot (bonus)	<code>df.groupby('Pclass')['Fare'].mean().plot(kind='bar')</code>	Comparer prix par classe

Partie 3 : Interprétation

- Les données sont-elles équilibrées ?
- Y a-t-il des valeurs extrêmes ?
- Quelle classe paie le plus ?