



**Institut Supérieur d'Informatique
et de Mathématiques de Monastir**



Cours : Entrepôt de Données

Chapitre 2: DATA WAREHOUSE

Enseignant: Dr. Nafaa haffar

Nafaa.haffar.5@gmail.com

Année Universitaire :2025-2026

PLAN

- Entrepôt de données
- Architecture des ED
- Modélisation multidimensionnelle OLAP
- Optimisation des Entrepôts de données

Le contexte

- ❑ **Besoin:** prise de décisions stratégiques et tactiques
- ❑ **Pourquoi:** besoin de réactivité
- ❑ **Qui:** les décideurs (non informaticiens)
- ❑ **Comment:** répondre aux demandes d'analyse des données, dégager des informations qualitatives nouvelles

Qui sont mes
meilleurs clients?

Quels Algériens
consomment
beaucoup de temps
de connexion?



Pourquoi et
comment le chiffre
d'affaire a baissé?

A combien s'
élèvent mes ventes
journalières?


Les données utilisables par les décideurs

❑ Données opérationnelles (de production)


- Bases de données (Oracle, SQL Server)
- Fichiers, ...
- Paye, gestion des RH, gestion des commandes...

❑ Caractéristiques de ces données:

- **Distribuées**: systèmes éparpillés
- **Hétérogènes**: systèmes et structures de données différents
- **Détaillées**: organisation des données selon les processus fonctionnels, données surabondantes pour l'analyse
- **Peu/pas adaptées à l'analyse** : les requêtes lourdes peuvent bloquer le système transactionnel
- **Volatiles**: pas d'historisation systématique



DES DONNEES AUX DECISIONS

A decorative graphic element in the bottom-left corner, consisting of a blue shape with a white outline, resembling a stylized head or a drop.

DES DONNEES AUX DECISIONS



- Donnée

LES DONNÉES SONT DES ÉLÉMENTS BRUTS ET NON TRAITÉS QUI REPRÉSENTENT DES FAITS OU DES MESURES QUANTIFIABLES, COLLECTÉES À PARTIR DE DIVERSES SOURCES. ELLES CONSTITUENT LA MATIÈRE PREMIÈRE DE L'INFORMATION ET NÉCESSITENT SOUVENT UN TRAITEMENT POUR DEVENIR SIGNIFICATIVES.

EXEMPLE

SAMSUNG A ATTEINT 10 000 VENTES . POUVEZ-VOUS ÉVALUER CE NOMBRE ?

A



TRES
FAIBLE

B



FAIBLE

C



MOYEN

D



FORT

EXEMPLE

SAMSUNG A ATTEINT 10 000 VENTES. POUVEZ-VOUS ÉVALUER CE NOMBRE ?

A B

C

D



TRES
FAIBLE



FAIBLE



MOYEN



FORT



TELL ME WHY ?

DES DONNEES AUX DECISIONS



- information

LES INFORMATIONS SONT DES DONNÉES COLLECTÉES, ORGANISÉES, TRAITÉES ET PRÉSENTÉES DE MANIÈRE À AVOIR UN SENS. ELLES FOURNISSENT DES DÉTAILS SIGNIFICATIFS SUR UN SUJET SPÉCIFIQUE, FACILITANT LA COMPRÉHENSION OU L'ANALYSE D'UNE SITUATION, SOUVENT PRÉSENTÉES SOUS FORME DE RAPPORTS OU DE GRAPHIQUES.



Exemple

SAMSUNG A ATTEINT 10 000 VENTES EN TUNISIE , 20000 VENTES AU JAPAN ET 7000 VENTES EN ITALIE. QUE POUVEZ VOUS CONCLURE ?



LES VENTES DE SAMSUNG
EN TUNISIE SONT FORTES



LES VENTES AU
JAPAN SONT TRES
FORTES



L'ITALIE N'EST PAS UN
BON MARCHE POUR
SAMSUNG



SAMSUNG DOIT INVESTIR UN
MONTANT IMPORTANT POUR
LE MARKETING EN TUNISIE

Exemple

SAMSUNG A ATTEINT 10 000 VENTES EN TUNISIE , 20000 VENTES AU JAPAN ET 7000 VENTES EN ITALIE. QUE POUVEZ VOUS CONCLURE ?



LES VENTES DE SAMSUNG EN
TUNISIE SONT FORTES



SAMSUNG DOIT INVESTIR UN
MONTANT IMPORTANT POUR
LE MARKETING EN TUNISIE

Exemple

SAMSUNG A ATTEINT 10 000 VENTES EN TUNISIE , 20000 VENTES AU JAPAN ET 7000 VENTES EN ITALIE. QUE POUVEZ VOUS CONCLURE ?



LES VENTES DE SAMSUNG
EN TUNISIE SONT FORTES



LES VENTES AU
JAPAN SONT TRES
FORTES



L'ITALIE N'EST PAS UN
BON MARCHE POUR
SAMSUNG



SAMSUNG DOIT INVESTIR UN
MONTANT IMPORTANT POUR
LE MARKETING EN TUNISIE

TELL ME WHY ?

DES DONNEES AUX DECISIONS



- connaissances

LES CONNAISSANCES RÉSULTENT DE L'ANALYSE ET DE L'INTERPRÉTATION DES INFORMATIONS, PERMETTANT DE TIRER DES CONCLUSIONS OU DE PRENDRE DES DÉCISIONS ÉCLAIRÉES SUR DES PROBLÈMES SPÉCIFIQUES, BASÉES SUR UNE COMPRÉHENSION APPROFONDIE ET CONTEXTUALISÉE.

Exemple

QUELLES SONT LES INFORMATIONS QUE VOUS POUVEZ TIRER DU
TABLEAU PRECEDANT ?



SAMSUNG DOIT CHANGER SA
STRATEGIE DE MARKETING EN
ITALIE



LE JAPAN EST UN
MARCHÉ STABLE
POUR SAMSUNG



L'ITALIE N'EST PAS ENCORE UN
BON MARCHÉ POUR
SAMSUNG



SAMSUNG DOIT INVESTIR UN
MONTANT IMPORTANT POUR
LE MARKETING EN TUNISIE

Exemple

QUELLES SONT LES INFORMATIONS QUE VOUS POUVEZ TIRER DU
TABLEAU PRECEDANT ?



SAMSUNG DOIT CHANGER SA
STRATEGIE DE MARKETING EN
ITALIE



LE JAPAN EST UN
MARCHE STABLE
POUR SAMSUNG



L'ITALIE N'EST PAS ENCORE UN
BON MARCHE POUR
SAMSUNG




SAMSUNG DOIT INVESTIR UN
MONTANT IMPORTANT POUR
LE MARKETING EN TUNISIE

DES DONNEES AUX DECISIONS



- décision

LES DÉCISIONS SONT DES CHOIX OU DES ACTIONS PRISES APRÈS AVOIR EXAMINÉ DES INFORMATIONS PERTINENTES, DANS LE BUT D'ATTEINDRE DES OBJECTIFS SPÉCIFIQUES, RÉSOUDRE DES PROBLÈMES OU RÉPONDRE À DES BESOINS, SOUVENT BASÉES SUR DES ANALYSES OU DES ÉVALUATIONS DE RISQUES.



APPLICATIONS TRANSACTIONNELLES VS APPLICATIONS DECISIONNELLES

DES DONNEES AUX DECISIONS

- applications transactionnelles OLTP

- Les applications transactionnelles sont principalement axées sur la collecte, le stockage et la gestion des données liées aux opérations

quotidiennes d'une organisation.

Elles sont conçues pour effectuer des transactions en temps réel, telles que la

- saisie des commandes, le traitement des paiements, la mise à jour des stocks, etc.

OLTP On Line Transaction Processing

On line vs Online

DES DONNEES AUX DECISIONS

- applications décisionnelles OLAP

Les applications **décisionnelles** sont axées sur **l'analyse** et la **compréhension**

- des données pour aider les **décideurs** à prendre des **décisions éclairées** et **stratégiques**.

- Elles sont conçues pour **extraire**, **transformer** et **analyser** les **données stockées** dans les **entrepôts de données** ou les **data marts**.

OLAP On Line Analytical Processing

INCOMPATIBILITE DE DEUX ACTIVITES



Problème

- les deux activités **OLTP** et **OLAP** ne peuvent coexister sur des données dans le même système d'informations : les objectifs de performances sont exactement opposés

mais pourquoi ?

- les requêtes complexes lourdes dégradent les performances des systèmes transactionnelles
- les **données temporelles** sont **reparties** entre **données actuelles** et **données archivées** rendant la **vue historique** des données très **difficiles** ou **impossible**

Le Décisionnel

- ❑ Les entreprises passent à **l'ère de l'information**
- ❑ **Défi** : Transformer une partie de leur système d'information qui avait une vocation de production à un **SI décisionnel** dont la vocation de pilotage devient majeure.
SI décisionnel
- ❑ Un **système d'information décisionnel (S.I.D.)** est un ensemble de données organisé de façon spécifique, approprié à la prise de décision.
- ❑ Finalité d'un système décisionnel :
 - ❑ Pilotage de l'entreprise
 - ❑ Pilotage de l'entreprise

Problématique

- Comment répondre aux demandes des décideurs?
 - En donnant un accès rapide et simple à l'information stratégique
 - En donnant du sens aux données


 Mettre en place un système d'information dédié aux applications décisionnelles:

Un Entrepôt de Données (Data Warehouse)


Orientation : Gestion

**Système d'Info.
Décisionnel**

**Orientation :
Pilotage**



Le processus de prise de décision



NAISSANCE DU DATAWAREHOUSE



Introduction

- ❑ Pourquoi le data warehouse ?
 - Améliorer les performances **décisionnelles** de l'entreprise
- ❑ Comment?
 - En répondant aux demandes d'analyse des décideurs
- ❑ Exemples
 - **Clientèle:** **Qui** sont mes clients? **Pourquoi** sont-ils mes clients?, **Comment** les **conserver** ou les faire revenir (préférence d'achat, habitudes, ...)? Ces clients sont-ils vraiment intéressants pour moi?
 - **Marketing, actions commerciales:** où placer ce produit dans les rayons?
Comment cibler plus précisément le mailing concernant ce produit?
 - **Exemple dans le domaine de sécurité ?**

Introduction

Raisons d'être d'un entrepôt de données

- Rassembler les données de l'entreprise dans un **même lieu** sans **surcharger** les BD (systèmes opérationnels)
- Permettre **un accès universel** à diverses sources de données et assurer la **qualité** des données
- **Extraire**, **filtrer**, et **intégrer** les informations pertinentes, à l'avance, pour des requêtes ultérieures
- Dégager des **connaissances** et faire un apprentissage sur l'entreprise, le marché et l'environnement

C'est quoi un entrepôt de données?

❑ Industrie (Inmon 1992)

- Collection de données **orientées sujets**
- Consolidées dans une **base de données unique**
- **Non volatiles** et **historisées** variant dans le temps
- organisées pour le support d'un **processus d'aide à la décision**

❑ Recherche (Stanford 1995)

- Dispositif de stockage d'informations **intégrées** de sources **distribuées**, **autonomes**, **hétérogènes**

définition

Un **datawarehouse** est une **infrastructure** de **gestion des données** qui **regroupe**, **stocke** et organise de **grandes quantités** de **données** provenant de **différentes** sources au sein d'une organisation. Son objectif principal est de fournir **un environnement centralisé** pour l'analyse et la prise de décision en offrant **un accès rapide** et **efficace** aux **données historiques** et **actuelles**.

Caractéristiques

Centralisation des données : Un datawarehouse centralise les données provenant de multiples sources de données internes et externes à l'entreprise. Des exemples ?

Intégration et transformation des données : Les données provenant de sources disparates sont intégrées, nettoyées et transformées afin de garantir la cohérence, la qualité et l'intégrité des données dans le datawarehouse.

Caractéristiques

Stockage optimisé : Les données sont stockées de manière optimisée pour les requêtes analytiques, souvent sous forme dénormalisée ou semi-dénormalisée.

Orientation analytique : Contrairement aux bases de données opérationnelles qui sont conçues pour prendre en charge les transactions en temps réel, un datawarehouse est orienté vers l'analyse des données et la prise de décision.

Caractéristiques

Stockage optimisé : Les données sont stockées de manière optimisée pour les requêtes analytiques, souvent sous forme dénormalisée ou semi-dénormalisée.

Orientation analytique : Contrairement aux bases de données opérationnelles qui sont conçues pour prendre en charge les transactions en temps réel, un datawarehouse est orienté vers l'analyse des données et la prise de décision.

Caractéristiques

Support à la prise de décision : Un datawarehouse fournit un accès aux données **historiques** et **actuelles**, ce qui permet aux décideurs de comprendre les tendances passées, d'identifier les **modèles** et de prendre des **décisions** éclairées basées sur des **analyses approfondies**.

CARACTERISTIQUES DES DONNES D'UN DATAWAREHOUSE

Caractéristiques des données d'un datawarehouse

Orientation sujet : Elles sont organisées autour de sujets spécifiques ou domaines d'intérêt, facilitant ainsi l'analyse multidimensionnelle et la prise de décision.

Intégration : Elles sont issues de différentes sources et sont intégrées pour garantir la cohérence et la compatibilité entre elles, grâce à des processus tels que l'extraction, la transformation et le chargement (ETL).

Caractéristiques des données d'un datawarehouse

Historisation : Elles incluent des données historiques, permettant l'analyse des tendances temporelles et l'évolution des


performances commerciales.

Non volatilité : Elles sont non volatiles, c'est-à-dire qu'elles ne sont pas modifiées une fois chargées dans le datawarehouse, assurant ainsi l'intégrité et la traçabilité des données au fil du temps.

Les 4 caractéristiques des data warehouse

1. Données orientées sujet:


- Regroupe les informations des différents métiers
- Ne tiens pas compte de l'organisation fonctionnelle des données




Les 4 caractéristiques des data warehouse

2. Données intégrées:

- Normalisation des données
- Définition d'un référentiel unique



Intégration de données



Caractéristiques des sources de données :

- Hétérogènes (schématique, sémantique),
- Autonomes
- Évolutives
- Réparties

Besoins :


- Intégration données
- Gestion de l'évolution des données

Les 4 caractéristiques des data warehouse


3. Données non volatiles

- Traçabilité des informations et des décisions prises
- Copie des données de production

Bases de production



Entrepôts de données



Les 4 caractéristiques des data warehouse

4. Données datées

- Les données persistent dans le temps
- Mise en place d'un référentiel temps

Base de
production

Image de la base en Mai 2017

Répertoire

Nom	Ville
Karim	Alger
Salim	Blida

Image de la base en Juillet 2018

Répertoire

Nom	Ville
Karim	Tipaza
Salim	Blida

Entrepôt
de
données

Calendrier


Code	Année	Mois
1	2017	Mai
2	2018	Juillet

Répertoire

Code	Nom	Ville
1	Karim	Alger
1	Salim	Blida
2	Karim	Tipaza

Datamart

- Sous-ensemble d'un entrepôt de données
- Destiné à répondre aux besoins d'un secteur ou d'une fonction particulière de l'entreprise
- Point de vue spécifique selon des critères métiers




Intérêt des datamart

- Nouvel environnement structuré et formaté en fonction des besoins d'un métier ou d'un usage particulier
- Moins de données que DW
 - Plus facile à comprendre, à manipuler
 - Amélioration des temps de réponse
- Utilisateurs plus ciblés

Data Warehouse Diagram




DATAWAREHOUSE



Architecture d'un ED: physique

Approche virtuelle (ou le non-entrepôt)




Inconvénients

- ☐ pas de réelle intégration des données
- ☐ différentes vues non-réconciliées
- ☐ les requêtes peuvent facilement bloquer les


transactions en cours

Architecture d'un ED: physique

Approche entrepôt



Architecture générale



Les flux de données

- **Flux entrant**

- Extraction: multi-source, hétérogène
- Transformation: filtrer, trier, homogénéiser, nettoyer
- Chargement: insertion des données dans l'entrepôt

- **Flux sortant**

- Mise à disposition des données pour les utilisateurs finaux

Les différentes zones de l'architecture

- **Zone de préparation (Staging area)**
 - Zone temporaire de stockage des données extraites
 - Réalisation des transformations avant l'insertion dans le DW:
 - Nettoyage
 - Normalisation...
 - Données souvent détruites après chargement dans le DW
- **Zone de stockage (DW, DM)**
 - On y transfère les données nettoyées
 - Stockage permanent des données
- **Zone de présentation**
 - Donne accès aux données contenues dans le DW
 - Peut contenir des outils d'analyse programmés:
 - Rapports
 - Requêtes...

Processus ETL (Extracting /Transforming/Loading)

- Le principe de l'entreposage des données est de rassembler de multiples données sources qui souvent sont **hétérogènes** en les rendant **homogènes** afin de les analyser.
- Ce travail d'homogénéisation nécessite des **règles** précises servant de **dictionnaire** (ou de **référentiel**) et qui seront mémorisées sous forme de **métadonnées** (information sur les données).
- Ces règles permettent d'assurer des tâches d'administration et de gestion des données entreposées.

ETL

Un système ETL est tout système qui permet :

- ☐ d'offrir un environnement de développement, des outils de gestion des opérations et de maintenance.
- ☐ de découvrir, analyser et extraire les données à partir de sources hétérogènes;
- ☐ de nettoyer et standardiser les données selon les règles d'affaires établies par l'entreprise;
- ☐ de charger les données dans un entrepôt de données dans et/ou les propager vers les data-marts.

ETL

L'alimentation d'un ED est un processus qui s'effectue en plusieurs étapes :

- ☐ Sélection des données sources
- ☐ Extraction des données
- ☐ Transformation
- ☐ Chargement

Sélection des données sources

- Quelles sont les données de production qu'il faut sélectionner pour alimenter l'ED ?
- Toutes les données sources ne sont forcément pas utiles.
 - Doit-on prendre l'adresse complète ou séparer le code postal ?
- Les données sélectionnées seront réorganisées pour servir à la fabrication **des informations**.
- La **dénormalisation** des données crée des liens entre les données et permet des accès différents

Sélection des données sources (suite)

La sélection des données utiles à partir des BD de production n'est pas simple à faire .

Les données sont :

- **hétérogènes** (différents SGBD et différentes méthodes d'accès);
- **diffuses** (différents environnements matériels et différents réseaux interconnectés ou non);
- **complexes** (différents modèles logiques et physiques principalement orientés vers les traitements transactionnels).
- La définition de la granularité dépend du niveau de raffinement de l'information qu'on veut obtenir.

Sélection des données sources (suite)

Il existe plusieurs niveaux de données :

- ❑ Les données sont parfois assemblées avant d'être injectées dans l'ED permettant une vision intégrée et transversale de l'entreprise.
- ❑ Cette forme de données constitue **le niveau le plus fin** au niveau de l'ED : ceux sont **les données de détail**. Elles peuvent être agrégées et constituent ainsi un autre niveau de détail.
- ❑ Elles seront par la suite **structurées** dans des espaces d'analyse (soit des **cubes de données**, soit des **data marts**).
- ❑ Elles seront finalement à **un niveau de présentation**, où elles peuvent avoir plusieurs formes (tableaux, graphiques, tableaux de bord, règles de connaissances...).

Extraction des données

- ❑ L'extraction peut se faire à travers un **outil d'alimentation** qui doit travailler de façon **native** avec les SGBD qui gèrent les données sources.
- ❑ Ou alors créer des **programmes extracteurs**. L'inconvénient de cette approche est le risque de faire des extractions erronées, incomplètes et qui peuvent biaiser l'ED.
- ❑ Il faut gérer les anomalies en les traitant et en gardant une trace

Extraction des données

- ❑ L'extraction doit se faire conformément aux règles précises du référentiel.
- ❑ Elle ne doit pas non plus perturber les activités de production.
- ❑ Il faut faire attention aux données cycliques. Celles qu'on doit calculer à chaque période, pour pouvoir les prendre en considération.
- ❑ L'extraction peut se faire en interne selon l'horloge interne ou par un planificateur ou par la détection d'une donnée cible (de l'ED) ; ou en externe par des planificateurs externes.
- ❑ Les données extraites doivent être marquées par “*horodatage*” afin qu'elles puissent être pistées.

Transformation

C'est une suite d'opérations qui a pour but de rendre les données cibles **homogènes** et puissent être traitées de façon **cohérente**.

Exemple

Donnés sources

Appli 1 : male, femelle

Appli 2 : 1, 0

Appli 3 : Masculin, féminin

données cibles

m, f

m, f

m, f

Donnés sources

Appli 1 : \$1 500

Appli 2 : 160 €

Appli 3 : 2 000£

données cibles

179121 DZD

21435 DZD

311950 DZD

Transformation

- ❑ Les données doivent alors être filtrées afin d'éliminer les données aberrantes: données sans valeurs, avec des valeurs manquantes.
- ❑ Souvent dans les bases de production, certaines données sont sémantiquement fausses.
- ❑ Pour avoir une alimentation de qualité, il faut avoir une bonne connaissance des données à entreposer et des règles qui les régissent. Savoir corriger les données pour les doter d'un vrai sens sémantique.

Transformation

- ❑ L'ensemble des données sources, après nettoyage ou transformation d'après des règles précises ou par application de programmes, seront restructurées et converties dans un format cible.
- ❑ Il faut synchroniser les données pour que les valeurs

Data Cleaning

☐ Valeurs manquantes (nulles)

- Ignorer le tuple
- Remplacer par une valeur fixe ou par la moyenne

☐ Valeurs erronées ou inconsistantes

- Générées en présence de bruits
- Détecter par une analyse de voisinage
 - Écart par rapport à la moyenne
 - Factorisation en groupes
- Remplacer par une valeur fixe ou par la moyenne

☐ Inspection manuelle de certaines données possible

Chargement

- ❑ C'est l'opération qui consiste à charger les données nettoyées et préparées dans le DW.
- ❑ C'est une opération qui risque d'être assez longue. Il faut mettre en place des stratégies pour assurer de bonnes conditions à sa réalisation et définir la politique de rafraîchissement.
- ❑ C'est une phase plutôt mécanique et la moins complexe.

Chargement

- ❑ Le **dictionnaire** (ou **référentiel**) de données est constitué de l'ensemble des métadonnées.
- ❑ Il renferme des informations sur toutes les données de l'ED.
- ❑ Il renferme également des informations sur chaque étape lors de la construction du DW ; sur le passage d'un niveau de données à un autre lors de l'exploitation du DW.
 - Le rôle des métadonnées est de permettre :
 - La définition des données
 - La fabrication des données
 - Le stockage des données
 - L'accès aux données
 - La présentation des données.

Catégories des systèmes d'ETL

Il existe trois catégories d'outils ETL :

1. **Engine-based** : les transformations sont exécutées sur un serveur ETL,

1. *Engine-based*

disposant en général d'un référentiel. Ce genre d'outil dispose d'un moteur

de transformation ;

2. **Database-embedded** : les transformations sont intégrées dans la BD ;

3. **Code-generators** : les transformations sont conçues et un code est

3. *Code-generators*

généré. Ce code est déployable indépendamment de la base de données.

Catégories des systèmes d'ETL

Avantages des suites ETL :

- ✓ Développement simple, rapide et moins coûteux. Les coûts de l'outil seront amortis rapidement pour les projets sophistiqués ou de grandes envergures.
- ✓ Des ressources disposant de connaissances du domaine d'affaire et n'ayant pas de grandes compétences en programmation peuvent développer avec l'outil.
- ✓ Les outils ETL intègrent des référentiels de gestion des méta-data, tout en permettant de synchroniser les méta-data avec les systèmes sources, les BDs de l'ED et autres outils BI.
- ✓ Les outils ETL permettent la génération automatique du méta-data à chaque étape du processus ETL et renforcent la mise en place d'une méthodologie commune de gestion de méta-data qui doit être respectée par tous les développeurs.
- ✓ Les outils ETL disposent de programme intégré qui permet de faciliter la documentation, la création et la gestion de changement. L'outil ETL doit bien gérer les dépendances complexes et les erreurs qui peuvent surgir en cours d'exécution.

Catégories des systèmes d'ETL

Avantages des suites ETL (suite) :

- ✓ Le référentiel de méta-data des outils ETL peut produire automatiquement des rapports de mise en correspondance des données et d'analyse de dépendance de données
- ✓ Les outils ETL disposent de connecteurs intégrés pour la plupart des sources de données. Ils permettent aussi d'effectuer des conversions complexes de types de données (selon la source et la destination)
- ✓ Les outils ETL offrent des mécanismes de cryptage de compression en ligne de données
- ✓ La plupart des outils ETL offre une très bonne performance même pour une grande quantité de données.
- ✓ Un outil ETL peut, le cas échéant, gérer des scénarios d'équilibrage de la charge entre les serveurs.
- ✓ Un outil ETL peut être complété ou amélioré en utilisant le scripting ou la programmation.

Catégories des systèmes d'ETL

Avantages des ETL-Maison :

- ✓ Les outils de tests unitaires automatique sont disponibles seulement pour les outils développés maison.
- ✓ Les techniques de programmation orientée objet permettent de rendre consistantes la gestion des erreurs, la validation et la mise à jour des méta-data.
- ✓ Il est possible de gérer manuellement les méta-data dans le code et de créer des interfaces pour la gestion de ces dernières
- ✓ .Disponibilité des programmeurs dans l'entreprise.
- ✓ Un outil ETL est limité aux capacités du fournisseur.
- ✓ Un outil ETL est limité à l'outil de scripting propriétaire.
- ✓ Un outil développé maison donne une grande flexibilité et si le besoin se présente. Il est possible de tout faire.

Administration d'un ED

- ❑ L'ED est un aspect physique du SI de l'entreprise. Il doit être par conséquent évolutif. Les données doivent donc changer. On doit procéder à d'autres alimentations et donc gérer l'actualisation des données.
- ❑ Il existe des outils qui prennent en charge les tâches de rafraîchissement des données.
- ❑ Ils procèdent par réplication pour propager les maj effectuées dans les BD sources, dans l'ED.
- ❑ Le mécanisme de réplication est une opération de copie de données d'une BD vers une ou plusieurs BD.
- ❑ Les réplications sont alors synchrones ou asynchrones.
- ❑ Le rafraîchissement des données peut se faire également par des processus de transformation qui exploitent les méta-données.

Administration d'un ED (suite)

- ☐ La fonction d'administration porte sur un aspect fonctionnel (*qualité et la pérennité des données*) mais aussi sur un aspect technique (*maintenance, optimisation, sécurisation,...*)
- ☐ Elle concerne l'ensemble des tâches du processus d'entreposage de la sélection des données de production à la mise à disposition pour construire les espaces d'analyse.
- ☐ L'administrateur de l'ED doit maîtriser la gestion des données (*données, provenance des données, méta-données*).
- ☐ Les données agrégées sont aussi une production (*information*) de l'entreprise comme les données de production, doivent être entreposées.

Administration d'un ED (suite)

- ❑ La fonction de DBA est très recherchée
- ❑ Les DBA sont bien rémunérés (mieux que les développeurs)
- ❑ Les compétences demandées chez les DBA :
 - ❑ Data warehousing (très recherché)
 - ❑ Services de transformation des données (ETL)
 - ❑ Environnement de réplication

Rôles et responsabilités

1. Gestionnaire ETL

- ☐ Gérer quotidiennement l'équipe ETL.
- ☐ Définir les standards et procédures de l'environnement de développement ETL (Règles de nomenclature, Meilleures pratiques...)
- ☐ Superviser le développement, les tests et l'assurance qualité

2. Architecte ETL

- ☐ Concevoir l'architecture et l'infrastructure de l'environnement ETL.
- ☐ Concevoir le mappage logique de données.
- ☐ Livrer les routines ETL en production.
- ☐ Appréhender les besoins d'affaire.
- ☐ Connaître les systèmes source.
- ☐ Résoudre les problèmes techniques complexes.

Rôles et responsabilités (suite)

3. Développeur ETL

- ☐ Développer les routines ETL.
- ☐ Tester les routines ETL.
- ☐ S'assurer que les résultats du processus ETL répondent aux besoins d'affaire
(Collaboration étroite avec l'architecte ETL)

4. Analyste système

- ☐ Rassembler des besoins d'affaire.
- ☐ Documenter les besoins d'affaire.
- ☐ Travailler en collaboration avec toute l'équipe du DW (Non seulement celle du système ETL).

Rôles et responsabilités (suite)

5. Spécialiste qualité de données

- ☐ S'assurer de la qualité des données dans l'entrepôt de données en entier.
- ☐ S'assurer que les règles d'affaire sont bien implantées par les processus ETL (en collaboration avec l'analyste système et l'architecte ETL)

6.DBA

6. DBA

- ☐ Installer, configurer, migrer et maintenir la base de données.
- ☐ Traduire le modèle logique de données en modèle physique.

Exploitation de l'entrepôt

❑ Business Intelligence:

- Possibilité de visualiser et d'exploiter une masse importante de données complexes

❑ Trois principaux outils:

- OLAP : On-Line Analytical Processing
- Data mining: fouille de données
- Formulation de requêtes et visualisation des résultats

Architecture d'un entrepôt de données

- ❑ Souvent une architecture **trois-tiers**
 - Serveur d'entrepôt ("Warehouse Database Server")
 - Très souvent un système relationnel (ex. Oracle)
 - Serveur OLAP ("OLAP Server") de type ROLAP, MOLAP, ou HOLAP
 - Clients
 - Outils de requêtes et de production de rapports
 - Outils d'analyse et de prospection de données

Domaines d'applications

☐ Banque, Assurance

- Détermination des profils client (prêt, ...)

☐ Commerce

- Ciblage de clientèle
- Compagnies de grande production
- Aménagement des rayons (2 produits en corrélation)

☐ Compagnies téléphoniques

☐ Santé


Base de données vs. Entrepôt de donnée

Pourquoi dissocier une BD d'un ED?


- ❑ Les objectifs de **performances** dans les BD ne sont pas les mêmes que ceux dans les EDs :
 - BD : requêtes **simples (OLTP)**, méthodes d'accès et indexation
 - ED : requêtes OLAP souvent **complexes!!!**
- ❑ La nécessité de **combiner** des données provenant de diverses sources, d'effectuer des **agrégations** dans un ED et d'offrir des **vues multidimensionnelles**
- ❑ Les données d'un ED sont souvent non **volatiles** et ont donc une plus longue durée de vie que celles d'une BD

SGBD et DW

OLTP: On-Line
Transactional
Processing




OLAP: On-Line
Analitical
Processing



OLTP VS DW

OLTP	DW
Orienté transaction	Orienté analyse
Orienté application	Orienté sujet
Données courantes	Données historisées
Données détaillées	Données agrégées
Données évolutives	Données statiques
Utilisateurs nombreux, administrateurs/opérationnels	Utilisateurs peu nombreux, manager
Temps d'exécution: court	Temps d'exécution: long

Cycle de vie de l'entrepôt de données



Cycle de vie

❑ Spécification des besoins

- Rassembler clairement et fidèlement les besoins des utilisateurs (**décideurs**)
- Clarifier les objectifs spécifiques
 - Comportement de la clientèle, prévisions, etc. analyse de tendances de
- Énumérer les **dimensions**
- Définir **l'architecture du système** (modèle de données), **l'usage final** (rapports, requêtes, **outils d'analyse** et **visualisation**)

Cycle de vie

❑ Analyse

- Développer le schéma de l'entrepôt
- Définir les processus nécessaires à la mise en place de l'entrepôt (extraction de données à partir des sources, transformations)

❑ Conception (3 niveaux)

- **Conceptuel** : mise au point du schéma, définition des méta-données
- **Logique** : adapté aux particularités du serveur de l'entrepôt (ROLAP, MOLAP, etc.)
- **Physique** : choix d'index, vues matérialisées, fragmentation

Cycle de vie

❑ Construction

- Développer des programmes d'extraction, d'épuration et de transformation de données

❑ Déploiement

- Fournir une installation initiale incluant la connexion aux données sources, la synchronisation et la réplication de données
- Permettre des extensions futures
- Offrir la formation pour les groupes d'intervenants
- Offrir les divers mécanismes d'administration de l'ED (reprise, sécurité, performances)
- Offrir les outils nécessaires à l'exploitation des données et à la consultation des méta-données