

Institut Supérieur d'Informatique et des Mathématiques de Monastir



TECHNIQUES D'INDEXATION ET RECHERCHE MULTIMÉDIA

IMEN CHEBBI

Chapitre 4

1. Modèle Booléen étendu

2. Modèle flou-fuzzy based model (basé sur la logique floue)

Introduction:

- Prendre en compte l'importance des termes dans les documents et/ou dans la requête.
- Possibilité d'ordonner les documents sélectionnés.

Comment étendre le modèle booléen ?

- Interpréter les conjonctions et les disjonction



•Deux modèles :

- Modèle flou-fuzzy based model (basé sur la logique floue)
- Modèle booléen étendu- extended boolean model,



Modèle Booléen étendu: Principe

Combinaison des modèles booléen et vectoriel

- Document : liste de termes pondérés.
- Requête booléenne.
- Utilisation des distances algébriques pour mesurer la pertinence d'un document vis-à-vis à d'une requête.



Modèle booléen étendu: appariement

Modèle Vectoriel (Vector Space Model)

Soit.

$d_j (w_{1j}, w_{2j}, \dots, w_{tj})$

q : requête à deux termes

- $q_{\text{and}} = t_1 \text{ et } t_2$
- $q_{\text{or}} = t_1 \text{ ou } t_2$



$$RSV(d_j, t_1 \vee t_2) = \frac{\sqrt{(w_{1j}^2 + w_{2j}^2)}}{\sqrt{2}}$$

$$RSV(d_j, t_1 \wedge t_2) = 1 - \frac{\sqrt{((1 - w_{1j})^2 + (1 - w_{2j})^2)}}{\sqrt{2}}$$

Modèle Vectoriel (Vector Space Model)

En **technique d'indexation**, chaque document d_j est représenté comme un vecteur de poids :

$$d_j = (w_{1j}, w_{2j}, \dots, w_{nj})$$

où :

- w_{ij} = poids du terme t_i dans le document d_j
- souvent calculé avec **TF-IDF**

La requête est aussi représentée comme un vecteur.



Modèle Vectoriel (Vector Space Model)

Signification de la formule

Ici, la requête est :

$$q = t_1 \vee t_2$$

Donc la requête contient **deux termes reliés par OR**.

Dans le modèle vectoriel :

$$q = (1, 1)$$

(si on suppose des poids égaux pour les deux termes).



Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)

Le **RSV** mesure la similarité entre la requête et le document.

On utilise généralement la **similarité cosinus** :

$$RSV(d_j, q) = \frac{d_j \cdot q}{||d_j|| ||q||}$$



Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)

1. Produit scalaire :

$$d_j \cdot q = w_{1j} + w_{2j}$$

Mais dans cette formule spécifique, on considère une **combinaison OR probabiliste ou normalisée**, ce qui donne :

$$\sqrt{w_{1j}^2 + w_{2j}^2}$$



Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)

2. Normalisation

La norme du vecteur requête :

$$||q|| = \sqrt{1^2 + 1^2} = \sqrt{2}$$

D'où le dénominateur :

$$\sqrt{2}$$



Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)

Interprétation

$$RSV(d_j, t_1 \vee t_2)$$

représente :

- ✓ Le degré de pertinence du document d_j
- ✓ Par rapport à une requête contenant t_1 OU t_2
- ✓ En tenant compte des poids des deux termes



Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)

Interprétation

- Si le document contient fortement **les deux termes**, le RSV sera élevé.
- S'il contient seulement un terme avec un poids élevé → score moyen.
- S'il ne contient aucun terme → $RSV = 0$.



Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)

La racine :

$$\sqrt{w_{1j}^2 + w_{2j}^2}$$

correspond à la **norme euclidienne partielle** du document projetée sur les dimensions t_1 et t_2 .

Donc on mesure la **distance géométrique** dans l'espace vectoriel.



Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)

- Cette formule est une version normalisée du calcul de similarité dans le modèle vectoriel pour une requête :

$$t_1 v t_2$$

- Elle combine les poids des deux termes et les normalise par la taille de la requête.



Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)



La formule :

$$RSV(d_j, t_1 \wedge t_2) = 1 - \frac{\sqrt{(1 - w_{1j})^2 + (1 - w_{2j})^2}}{\sqrt{2}}$$

correspond au calcul de pertinence d'un document pour une requête **AND** dans le modèle vectoriel.

Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)



Chaque document d_j est représenté par :

$$d_j = (w_{1j}, w_{2j})$$

où :

- w_{1j} = poids du terme t_1 dans le document
- w_{2j} = poids du terme t_2
- Les poids sont généralement normalisés entre 0 et 1 (ex: TF-IDF normalisé)

Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)



Pour une requête :

$$q = t_1 \wedge t_2$$

On veut que le document soit **fort** sur les deux termes.

Le vecteur idéal est donc :

$$(1, 1)$$

Donc on mesure la **distance** entre le document et le point idéal (1,1).

Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)



- ◆ Distance euclidienne au point idéal :

$$\sqrt{(1 - w_{1j})^2 + (1 - w_{2j})^2}$$

Plus cette distance est petite → plus le document est proche du cas idéal.

Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)



◆ Normalisation

La distance maximale possible est :

$$\sqrt{(1 - 0)^2 + (1 - 0)^2} = \sqrt{2}$$

Donc on divise par $\sqrt{2}$ pour obtenir une valeur entre 0 et 1.

Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)



◆ Pourquoi "1 - ..." ?

Parce que :

- Distance petite → document pertinent
- Distance grande → document non pertinent

Donc on inverse :

$$RSV = 1 - \text{distance normalisée}$$

Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)



Cas	(w_{1j})	(w_{2j})	RSV
Les deux forts	1	1	1 (max)
Un seul fort	1	0	≈ 0.29
Aucun	0	0	0

Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)

Différence avec le OR



OR (v)

$$RSV = \frac{\sqrt{w_{1j}^2 + w_{2j}^2}}{\sqrt{2}}$$

- ✓ Mesure la présence d'au moins un terme
- ✓ Plus tolérant

Modèle Vectoriel (Vector Space Model)

Calcul du RSV (Retrieval Status Value)

Différence avec le OR



AND ($\wedge$)

$$RSV = 1 - \text{distance au point } (1,1)$$

- ✓ Exige que les deux termes soient présents
- ✓ Plus strict

ENSEMBLES FLOUS

- ❖ Théorie des ensembles flous:
 - Un cadre pour représenter les ensembles dont les bornes ne sont pas bien définis
 - L'objectif principal est l'introduction de la notion de degré d'appartenance d'un élément à un ensemble

base
de
données

ENSEMBLES FLOUS

– Contrairement à la théorie des ensembles où un élément est dans l'ensemble ou ne l'est pas, dans les ensembles flous, l'appartenance est mesurée par un degré variant entre 0 et 1:

- 0 → non appartenance
- 1 → appartenance complète

ENSEMBLES FLOUS: DÉFINITION

27

Un sous ensemble A d'un univers de discours U est caractérisé par une fonction d'appartenance: $\mu_A: U \rightarrow [0,1]$ qui associe à chaque élément u de U un nombre $\mu_A(u)$ dans $[0,1]$,

Soient A et B deux sous-ensembles flous de U

- **Complément $\mu_{\bar{A}}(u)$:**
- **Union**
- **Intersection**

$$\mu_{\bar{A}}(u) = 1 - \mu_A(u)$$

$$\mu_{A \cup B}(u) = \max(\mu_A(u), \mu_B(u))$$

$$\mu_{A \cap B}(u) = \min(\mu_A(u), \mu_B(u))$$

MODÈLE FLOU DE RI

- Le mécanisme de pondération consiste à représenter un document par un sous-ensemble flou des termes d'indexation T .
- Chaque terme $t_j \in T$ appartient à un document d_i de la collection C à un certain degré $\mu_C(d_i, t_j) \in [0, 1]$, qui est choisi de façon à refléter le degré de représentativité du terme par rapport au document.

MODÈLE FLOU DE RI

- En théorie des sous-ensembles flous, la fonction μ est la fonction d'appartenance d'un élément à un ensemble, et la valeur $\mu_{E(x)}$ (dans l'intervalle unité) représente le degré d'appartenance de l'élément x à l'ensemble E .

MODÈLE FLOU DE RI

- On note: $d_i = \{\alpha_1/t_1, \dots, \alpha_m/t_m\}$, où $\{t_1, \dots, t_m\}$ sont les termes présents dans d_i et $\alpha_j = \mu_C(d_i, t_j)$ le degré d'appartenance du terme t_j dans le document.

MODÈLE FLOU DE RI

Documents du corpus Exemple :

$$d_1 = \{1/bd, 0.33/xml\}$$

$$d_2 = \{1/bd, 1/xml\}$$

$$d_3 = \{0.25/bd, 1/réseau\}$$

$$d_4 = \{1/xml\}$$

MODÈLE FLOU : CALCUL DE SIMILARITÉ

32



- Soient :
 - Termes: $t_1, t_2, \dots, t_n$
 - Document: $d(w_1, w_2, \dots, w_n)$
- *Requête disjonctive* : $q_{or} = (t_1 \vee t_2 \vee \dots \vee t_n)$
 - $RSV(q_{or}, d) := \max(w_1, w_2, \dots, w_n)$

MODÈLE FLOU : CALCUL DE SIMILARITÉ

33



- Requête conjonctive : $q_{\text{and}} = (t_1 \wedge t_2 \wedge \dots \wedge t_n)$
 - $RSV(q_{\text{and}}, d) = \min(w_1, \dots, w_n)$
- **Généralisation**
 - $RSV(d, q_1 \wedge q_2) = \min(RSV(d, q_1), RSV(d, q_2))$,
 - $RSV(d, q_1 \vee q_2) = \max(RSV(d, q_1), RSV(d, q_2))$,

MODÈLE FLOU : CALCUL DE SIMILARITÉ

Exemple:

$$d_1 = \{1/bd, 0.33/xml\}$$

$$q = (bd \vee \text{réseau}) \wedge \neg xml$$

$$\text{sim}(d_1, q) = \min(\max(\text{poids}(bd, d_1), \text{poids}(\text{réseau}, d_1)), 1 - \text{poids}(xml, d_1)) = 0.67$$

➤ Le document d_1 répond à la requête q avec un degré de pertinence de 0.67.




MODÈLE FLOU : AVANTAGES

- En comparant cette extension avec le modèle standard, il est assez facile de voir les avantages.
- Le plus important est la possibilité de mesurer le degré de correspondance entre un document et une requête dans $[0, 1]$.

MODÈLE FLOU : AVANTAGES

- Les documents puissent être ordonné dans l'ordre décroissant de leur correspondance avec la requête.
- Cette représentation plus raffinée, car on peut exprimer dans quelle mesure un terme est important (représentatif) dans un document.



MERCI