

Institut Supérieur d'Informatique et des Mathématiques de Monastir




TECHNIQUES D'INDEXATION ET RECHERCHE MULTIMÉDIA

IMEN CHEBBI

Chapitre 5

1.Modèle probabiliste

2



Introduction:

- Le modèle probabiliste est fondé sur la théorie des probabilités.
- Il suppose l'existence d'une classe de documents pertinents et d'une classe de documents non pertinents pour une requête



- Les approches probabilistes nécessitent un ensemble de documents obtenus en demandant aux utilisateurs de fournir des jugements de pertinence par rapport aux résultats de requête.



- La base de l'apprentissage est utilisée pour calculer le poids du terme par l'estimation des probabilités conditionnelles qu'un terme se produit dans un document pertinent (ou non pertinent).



- Les méthodes probabilistes génèrent des indexes complexes basés sur des informations sur la dépendance des termes.



- Puisque, cela nécessite la prise en considération d'un nombre exponentiel de combinaisons des termes,
- Pour chaque combinaison, il exige l'estimation, des probabilités de coïncidences dans les documents pertinents et non pertinents, seules certaines paires de termes dépendants sont pris en compte dans la pratique.



- En théorie, ces dépendances peuvent être pour des utilisateurs spécifiques.



MODÈLE PROBABILISTE

Soit la requête q composée de séquence de termes:

$$q = q_1 q_2 \cdot \dots q_m,$$

et

un ensemble de documents $D = d_1; d_2; \dots; d_N$.



MODÈLE PROBABILISTE

$P(PERT)$: est la probabilité de pertinence, c'est-à-dire, la chance de tomber sur un document pertinent, si on choisit un document au hasard dans le corpus.



MODÈLE PROBABILISTE



P(NPERT): est la probabilité d'avoir un document non pertinent si on réalise un tirage au hasard.

Modèle probabiliste

- $P(D)$ est la probabilité d'extraire le document D du corpus.
- Le modèle probabiliste tente d'estimer la probabilité $P(PERT|D)$ (resp. $P(NPERT|D)$) qu'un document d appartienne à la classe des documents pertinents (resp. non pertinents).



Modèle probabiliste

- Seules la présence et l'absence de termes dans les documents et dans les requêtes sont considérées comme des caractéristiques observables.
- Autrement dit, les termes ne sont pas pondérés, mais prennent seulement les valeurs 0 (absent) ou 1 (présent).



Modèle probabiliste

- Lorsque l'indépendance des mots est supposée, le modèle probabiliste sera simplement une classification binaire de type Bayes Naïf, qui vise à classer les documents comme pertinents ou non pertinents.



Modèle probabiliste

En utilisant la règle de Bayes, un document est considéré comme pertinent si :

$$P(D|PERT)P(PERT) > P(D|NPERT)P(NPERT)$$

- **P(D|PERT)** : probabilité d'observer ce document si le document est pertinent
- **P(PERT)** : probabilité *a priori* qu'un document soit pertinent
- **P(D|NPERT)** : probabilité d'observer ce document s'il n'est pas pertinent
- **P(NPERT)** : probabilité *a priori* qu'un document ne soit pas pertinent



Modèle probabiliste

On divise les deux côtés par $P(D|NPERT) P(PERT)$ et on obtient :

$$\frac{P(D|PERT)}{P(D|NPERT)} > \frac{P(NPERT)}{P(PERT)}$$



Modèle probabiliste

- Les modèles probabilistes sont également connus sous le nom de modèles de vraisemblance de documents. Donc, les documents sont ensuite classés selon:

$$P(PERT|R, D) = \frac{P(D|PERT)}{P(D|NPERT)}$$

$P(PERT | R, D)$: Probabilité que le document soit pertinent sachant R et D



Modèle probabiliste

$$P(D \mid PERT)$$

- Probabilité d'obtenir le document D si le document est pertinent

$$P(D \mid NPERT)$$

- Probabilité d'obtenir le document D si le document n'est pas pertinent



Modèle probabiliste

Un modèle plus sophistiqué que le précédent calcule $P(D|PERT)$ à partir des termes apparaissant dans D_i :

$$P(D|PERT) = \prod_{t_j \in D_i} P(t_j|PERT) \times \prod_{t_j \in D_i} (1 - P(t_j|PERT))$$

$$P(D|NPERT) = \prod_{t_j \in D_i} P(t_j|NPERT) \times \prod_{t_j \in D_i} (1 - P(t_j|NPERT))$$



Modèle probabiliste

La valeur de $P(D_i|PERT)$ est estimée comme étant le produit de probabilités associées à chaque terme dans le document, multipliées par le produit des probabilités que les termes absents (n'apparaissent) pas dans un document pertinent:

$$\log \frac{P(D|PERT)}{P(D|NPERT)} = \sum_{t_j \in D_i} \log(P(t_j|PERT)) + \sum_{t_j \in D_i} \log(1 - P(t_j|PERT)) \\ - \sum_{t_j \in D_i} \log(P(t_j|NPERT)) - \sum_{t_j \in D_i} \log(1 - P(t_j|NPERT))$$



Modèle probabiliste

La valeur $\log \frac{P(D|PERT)}{P(D|NPERT)}$ est appelée *valeur de statut de recherche* et le but est de trouver les documents qui la maximisent.

- Le problème est maintenant d'estimer $P(t_j|PERT)$ et $P(t_j|NPERT)$



Modèle probabiliste

Il existe deux manières d'estimer $P(t_j|PERT)$ et $P(t_j|NPERT)$:

1. L'estimation a priori de ces facteurs

1. Etablissement d'un échantillonnage des documents selon leur pertinence.



Modèle probabiliste

- ✓ L'estimation a priori de ces facteurs suggère de donner une valeur fixe à $P(t_j|PERT)$ et de calculer $P(t_j|NPERT)$ en fonction de sa distribution dans l'ensemble des documents.
- ✓ Plus un terme t_j est rare plus $P(t_j|NPERT)$ est basse et vice versa.



Modèle probabiliste

Le deuxième mode d'estimation consiste à établir un échantillonnage des documents selon leur pertinence. Supposons qu'il existe NDP documents pertinents et que NDP_{t_j} soit le nombre de documents pertinents contenant t_j .

On a alors :

$$P(t_j|PERT) = \frac{NDP_{t_j}}{NDP}$$



Modèle probabiliste

Par ailleurs, ND_{t_j} est le nombre des documents contenant t_j et ND est le nombre de documents total.

$P(t_j|NP\!ERT)$ est calculée par :

$$P(t_j|NP\!ERT) = \frac{ND_{t_j} - NDP_{t_j}}{ND - NDP}$$



Modèle probabiliste

Le problème de ce modèle réside dans le passage de l'estimation de la pertinence des documents à l'estimation de la pertinence des termes qui repose sur l'hypothèse de l'indépendance des termes



EXERCICE 1

27

On considère une collection de 3 documents :

Document	Contenu
D1	information retrieval system
D2	probabilistic information model
D3	retrieval model and ranking

La requête est :

$$Q = \{information, retrieval\}$$

On suppose :

- $P(R) = 0.5$
- $P(\bar{R}) = 0.5$

Probabilités des termes :

Terme	$P(t R)$	$P(t \neg R)$
information	0.8	0.3
retrieval	0.7	0.2

On utilise la fonction de score probabiliste :

$$Score(d) = \sum_{t \in Q \cap d} \log \frac{P(t|R)(1 - P(t|\bar{R}))}{P(t|\bar{R})(1 - P(t|R))}$$

Étape 1 : Calcul du poids de chaque terme

Terme : information

$$\begin{aligned}w_{information} &= \log \frac{0.8(1 - 0.3)}{0.3(1 - 0.8)} \\&= \log \frac{0.8 \times 0.7}{0.3 \times 0.2} \\&= \log \frac{0.56}{0.06} \\&= \log(9.33) \\&\approx 2.23\end{aligned}$$

Terme : retrieval

$$\begin{aligned}w_{\text{retrieval}} &= \log \frac{0.7(1 - 0.2)}{0.2(1 - 0.7)} \\&= \log \frac{0.7 \times 0.8}{0.2 \times 0.3} \\&= \log \frac{0.56}{0.06} \\&= \log(9.33) \\&\approx 2.23\end{aligned}$$

Étape 2 : Calcul du score des documents

Document D1

Contient :

information ✓

retrieval ✓

$$Score(D1) = 2.23 + 2.23$$

$$Score(D1) = 4.46$$

Document D2

Contient :

information ✓

retrieval ✗

$$\textit{Score}(D2) = 2.23$$

Document D3

Contient :

retrieval ✓

information ✗

$$Score(D3) = 2.23$$


Étape 3 : Classement final

Document	Score
D1	4.46
D2	2.23
D3	2.23

Classement :

$$D1 > D2 = D3$$

Donc **D1** est le document le plus pertinent pour la requête.



Le modèle probabiliste classe les documents selon la **probabilité de pertinence** basée sur la présence des termes de la requête.

EXERCICE 2

On considère une collection de 4 documents :

Document	Termes
D1	data mining techniques
D2	information retrieval data
D3	probabilistic retrieval model
D4	data analysis model

La requête est :

$$Q = \{data, retrieval\}$$

Les probabilités estimées sont :

Terme	$P(t R)$	$P(t \neg R)$
data	0.6	0.4
retrieval	0.9	0.2

On utilise la formule :

$$Score(d) = \sum_{t \in Q \cap d} \log \frac{P(t|R)(1 - P(t|\bar{R}))}{P(t|\bar{R})(1 - P(t|R))}$$

Étape 1 : Calcul du poids des termes

Terme data

$$\begin{aligned}w_{data} &= \log \frac{0.6(1 - 0.4)}{0.4(1 - 0.6)} \\&= \log \frac{0.6 \times 0.6}{0.4 \times 0.4} \\&= \log \frac{0.36}{0.16} \\&= \log(2.25) \\&\approx 0.81\end{aligned}$$

Terme retrieval

$$\begin{aligned}w_{retrieval} &= \log \frac{0.9(1 - 0.2)}{0.2(1 - 0.9)} \\&= \log \frac{0.9 \times 0.8}{0.2 \times 0.1} \\&= \log \frac{0.72}{0.02} \\&= \log(36) \\&\approx 3.58\end{aligned}$$

Étape 2 : Score des documents

Document D1

Contient :

data ✓

retrieval ✗

$$Score(D1) = 0.81$$

Document D2

Contient :

data ✓

retrieval ✓

$$Score(D2) = 0.81 + 3.58$$

$$Score(D2) = 4.39$$

Document D3

Contient :

retrieval ✓

data ✗

$$Score(D3) = 3.58$$

Document D4

Content :

data ✓

retrieval ✗


$$Score(D4) = 0.81$$

Étape 3 : Classement des documents

Document	Score
D2	4.39
D3	3.58
D1	0.81
D4	0.81

Classement final :

$$D2 > D3 > D1 = D4$$



Le document **D2** est le plus pertinent car il contient **les deux termes de la requête.**

MERCI