

TD3 – Techniques d'Indexation et de Recherche Multimédia

Exercice 1 : Evaluation: Rappel et précision

Un système de recherche d'information retourne 3 documents pertinents et 2 documents non pertinents. Il existe au total 8 documents pertinents dans la collection. Quelle est la précision de ce système pour cette recherche, et quel est son rappel ?

Exercice 2 : Processus d'indexation

Un moteur de recherche collecte des documents et les envoie à un indexeur, qui emploie les modules suivants:

- un stemmer;
- un détecteur de langue pour détecter le langage de chaque document
- un éliminateur de mots (stop-word)
- un filtre qui détecte le format du document (pdf, word, etc)

Donner l'ordre dans lequel ces modules doivent être exécutés par l'indexeur d'un document

Exercice 3 : Index inverse

On dispose d'une requête sur deux mots. Pour l'un des termes le Posting List est formé par les 16 entrées suivantes : [4,6,10,12,14,16,18,20,22,32,47,81,120,122,157,180]

Et le second terme est formé par un Posting List à entrée unique [47]. Calculez le nombre de comparaisons nécessaires pour trouver l'intersection des deux Posting List.

Exercice 4 :

On suppose que seuls les termes de « fréquence de poids » sont utilisés (pas de facteur inverse de fréquence), et les seuls mots ignorés « stopwords » sont "is" et are. Calculez le cosinus de similarités des deux documents suivants :

- a) "precision is very very high"
- b) "high precision is very very very important"