

TD3 – Techniques d'Indexation et de Recherche Multimédia

Exercice 1 : Evaluation: Rappel et précision

On a :

- Documents pertinents retournés = 3
- Documents non pertinents retournés = 2
- Total retournés = 3 + 2 = 5
- Total pertinents dans la collection = 8

Précision (Precision)

La précision mesure la proportion de documents pertinents parmi ceux retournés :

$$\text{Précision} = \frac{3}{5} = 0,6 = 60\%$$

Rappel (Recall)

Le rappel mesure la proportion de documents pertinents retrouvés parmi tous les pertinents existants :

$$\text{Rappel} = \frac{3}{8} = 0,375 = 37,5\%$$

Résultats finaux :

- **Précision = 60 %**
- **Rappel = 37,5 %**

Le système est assez précis (peu d'erreurs dans les résultats retournés), mais il manque encore plusieurs documents pertinents (rappel faible).

Exercice 2 :

Pour indexer correctement un document, les modules doivent être appliqués dans un ordre logique qui respecte les dépendances entre traitements.

Ordre correct des modules :

1. **Filtre de format du document** (PDF, Word, etc.)
→ Permet d'extraire le texte brut du document, indispensable avant tout traitement.
2. **Détecteur de langue**
→ Nécessaire pour adapter les traitements linguistiques (stop-words et stemming dépendent de la langue).
3. **Éliminateur de mots vides (stop-words)**
→ Supprime les mots fréquents non significatifs (ex: "le", "de", "and"...).
4. **Stemmer (racinisation)**
→ Réduit les mots à leur racine (ex: "manger", "mangeons" → "mang").

Réponse finale :

Filtre de format → Détecteur de langue → Éliminateur de stop-words → Stemmer

Exercice 3 :

On utilise l'algorithme classique d'intersection de listes triées (type *merge*).

Comme la deuxième liste contient **un seul élément (47)**, on va comparer cet élément avec les éléments de la première liste **jusqu'à trouver 47**.

On compare 47 avec chaque élément de la première liste :

1. 47 vs 4
2. 47 vs 6
3. 47 vs 10
4. 47 vs 12
5. 47 vs 14
6. 47 vs 16
7. 47 vs 18
8. 47 vs 20
9. 47 vs 22
10. 47 vs 32
11. 47 vs 47 ☒ (match trouvé)

Nombre total de comparaisons : **11**

Il faut **11 comparaisons** pour trouver l'intersection entre les deux Posting Lists.

Exercice 4 :

Données

- On utilise uniquement la **fréquence des mots (TF)**
- Les **stopwords ignorés** : “is”, “are”

Étape 1 : Nettoyage des documents

- Document a :**
“precision is very very high”
→ sans stopwords :
precision, very, very, high
- Document b :**
“high precision is very very very important”
→ sans stopwords :
high, precision, very, very, very, important

Étape 2 : Vocabulaire commun

Ensemble des termes :

{precision, very, high, important}

 Étape 3 : Vecteurs TF

Terme	Doc a	Doc b
precision	1	1
very	2	3
high	1	1
important	0	1

Donc :

- $A = (1, 2, 1, 0)$
- $B = (1, 3, 1, 1)$

 Étape 4 : Formule du cosinus

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

Étape 5 : Calculs

◆ Produit scalaire

$$\begin{aligned} A \cdot B &= (1 \times 1) + (2 \times 3) + (1 \times 1) + (0 \times 1) \\ &= 1 + 6 + 1 + 0 = 8 \end{aligned}$$

◆ Norme de A

$$\|A\| = \sqrt{1^2 + 2^2 + 1^2 + 0^2} = \sqrt{6}$$

◆ Norme de B

$$\|B\| = \sqrt{1^2 + 3^2 + 1^2 + 1^2} = \sqrt{12}$$

Étape 6 : Cosinus

$$\begin{aligned} \cos(\theta) &= \frac{8}{\sqrt{6} \times \sqrt{12}} \\ &= \frac{8}{\sqrt{72}} = \frac{8}{6\sqrt{2}} \\ &\approx 0.94 \end{aligned}$$

🎯 Résultat final

$$\cos(\theta) \approx 0.94$$

Les deux documents sont **très similaires** (valeur proche de 1), car ils partagent beaucoup de termes avec des fréquences proches.