

TD 5 – Techniques d'Indexation et de Recherche Multimédia

◆ Données

DocID	Texte	Longueur
D1	click go the shears boys click click click	8
D2	click click	2
D3	metal here	2
D4	metal shears click here	4

Fréquences des termes :

Doc	click	shears	metal
D1	4	1	0
D2	2	0	0
D3	0	0	1
D4	1	1	1

Question 1 : Modèle booléen

Requête : **metal OR click**

On sélectionne les documents contenant **au moins un des deux termes**.

- D1 → contient *click*
- D2 → contient *click*
- D3 → contient *metal*
- D4 → contient *metal* et *click*

Résultat : D1, D2, D3, D4 (tous les documents)

Question 2 : Modèle probabiliste

On utilise ici une estimation simple :

$$P(t|d) = \frac{\text{fréquence du terme}}{\text{taille du document}}$$

♦ Calcul des probabilités

1. Requête : click

Doc	Calcul	Score
D1	4 / 8	0.5
D2	2 / 2	1
D3	0 / 2	0
D4	1 / 4	0.25

👉 Classement : D2 > D1 > D4 > D3

2. Requête : shears

Doc	Calcul	Score
D1	1 / 8	0.125
D2	0	0
D3	0	0
D4	1 / 4	0.25

👉 Classement : D4 > D1 > D2 = D3

3. Requête : click shears

On suppose indépendance :

$$P(\text{click} \wedge \text{shears}|d) = P(\text{click}|d) \times P(\text{shears}|d)$$

Doc	Calcul	Score
D1	0.5×0.125	0.0625
D2	1×0	0
D3	0×0	0
D4	0.25×0.25	0.0625

👉 Classement : D1 = D4 > D2 = D3

Score final pour "click shears"

- D1 = 0.0625
- D4 = 0.0625
- D2 = 0
- D3 = 0

Documents les plus pertinents : D1 et D4 (égalité)